RL-001

从任务到决策
强化学习解决什么问题?

一次可审查的问题建模

讲解约 13 分钟 · 学习约 35 分钟

本课目标

1　写清楚任务中的观测、动作与奖励

2　手算一个三步决策的折扣回报

3　区分监督学习、Bandit 与多步 RL

前置：概率与期望、监督学习中的输入和目标

智能体与环境的交互

策略 π 把可用信息映射为动作选择

时刻	智能体 Agent	环境 Environment
t	读取 o_t，按策略选择 a_t	接收动作，产生结果
t + 1	读取新观测和奖励	返回 o_{t+1} 与 r_{t+1}

$$a_t \sim \pi(\cdot \mid o_t)$$

观测与状态

真实系统常常只向智能体提供部分信息

概念	含义	GUI 示例
观测 o_t	当前可获得的信息	截图、任务描述、近期操作
状态 s_t	足以预测后续变化的信息	页面与隐藏的应用状态

截图可能遗漏焦点、弹窗遮挡或后台状态

动作与奖励

动作需要改变结果，奖励需要表达任务目标

概念	模态路由示例	GUI 示例
动作 a_t	选择某个回答分支	点击、输入、滚动
奖励 r_{t+1}	回答收益减调用成本	任务成功收益减操作代价

模型损失与环境奖励承担不同角色

奖励如何组成回报

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots$$

G_t：从时刻 t 开始的累计折扣回报
r_{t+k+1}：第 k + 1 次后续动作获得的奖励

γ：折扣因子，通常取 $0 \le \gamma \le 1$
t：当前时间步，k：距离当前的步数

回合在终止处停止求和；持续任务的折扣和通常要求 $\gamma < 1$

三步 GUI 任务的手算

教学假设：两次操作各花费 1，第三步成功获得 10

动作序号	第 1 步	第 2 步	第 3 步
奖励	−1	−1	+10

$\gamma = 0.9$

$$G_0 = -1 + 0.9 \times (-1) + 0.9^2 \times 10 = 6.2$$

仅为回报计算示例，未运行真实 GUI 实验

监督学习、Bandit 与多步 RL

建模方式	训练反馈	动作的后续影响
监督学习	输入对应的目标或标签	通常不建模决策序列
Contextual Bandit	所选动作对应的收益	通常按单次收益评价
多步 RL	轨迹中的奖励反馈	动作影响后续信息与回报

单步路由可以先比较分类和 Bandit 基线

模态路由的教学建模

主要应用：收益、错误代价与资源消耗共同决定选择

字段	本课的候选定义
可用信息	query、已经获得的上下文、允许使用的信号
动作	文本分支或图像分支，仅为教学示例
反馈与奖励	可验证回答质量、调用成本和延迟
评价基线	固定路由、代价敏感分类、Contextual Bandit

输入来源、标签与业务代价需在真实任务中确认

路由收益的手算比较

教学假设：回答正确获得 10，错误收益为 0

分支	正确概率 p	调用成本 c	期望净收益
文本分支	0.70	0.5	6.5
图像分支	0.90	2.0	7.0

E[r | 分支] = 10p − c

成本若升至 3，图像分支收益变成 6.0

这些概率与成本全部是假设，未运行真实路由实验

SR 与 GUI 的适用边界

任务	需要先回答的问题	首轮比较基线
SR	可学习的决策是停止、参数选择还是逐步恢复?	固定计算量的现有 SR 方法
单次 GUI 定位	是否已有目标控件或坐标标签?	监督定位与检测模型
多步 GUI 操作	动作是否改变后续页面与任务进度?	现有规划与执行策略

任务存在可评估决策，才进入算法选择

建模容易失败的地方

奖励代理与真实目标不一致

例如只追求低调用成本，牺牲关键任务的回答质量

日志只记录所选分支，直接比较结果产生偏差

数据划分、合法动作或后续信息没有明确约束

先固定评价协议，再检验算法是否改善目标

三道理解题

1　截图与指令定位坐标，有标注但没有环境
当前怎样训练？多步保存任务还缺什么？

2　三步回报在 $\gamma = 0.9$ 和 $\gamma = 1$ 时各是多少？
为什么一次成功还不足以证明策略更好？

3　图像成本多少时，两种路由净收益相同？
只选中文本的日志，能否给图像标失败？

先自行作答，再查看讲义文末的参考答案

下一课与参考来源

RL-002　MDP 的严格定义

下一课将把本课的口头建模写成数学对象
并检查 Markov 假设

Sutton & Barto (2018)
Reinforcement Learning: An Introduction, 2nd ed.
第 1–3 章，重点第 3 章的交互与回报定义

OpenAI Spinning Up
Part 1 — Key Concepts in RL（官方教程）