RL-002

MDP 的严格定义
状态、动作与转移

2026-10-14 · 讲解约 13 分钟
学习 35～45 分钟

本课目标与前置

1　判断哪些信息构成合适的状态

2　给出合法动作、转移概率与奖励

3　核对轨迹期望与任务结束条件

前置 RL-001：交互、策略、奖励与折扣回报

MDP 的组成

一个模型需要同时说明环境动态和评价目标

组成	需要定义的内容
状态与初始分布	状态集合，以及任务从哪里开始
动作	每个状态允许选择的动作 $A(s)$
环境动态 p	给定当前状态和动作，下一状态与奖励的分布
目标	折扣因子 γ、回报形式和任务结束条件

Markov 条件

$$p(s', r \mid h_t, a_t) = p(s', r \mid s_t, a_t)$$

h_t：到时刻 t 的状态、动作与奖励历史
s_t：当前状态，a_t：当前动作

s'、r：下一状态与执行动作后收到的奖励
相同状态和动作，应给出相同的后续分布

假设必须对应实际任务，加入历史后仍需检查状态是否充分

相同截图可能对应不同状态

GUI 反例：界面外观相同，保存后的结果不同

可见界面	隐藏条件 A	隐藏条件 B
同一张表单截图	历史 H_1：当前未登录	历史 H_2：当前已登录
点击保存	可能要求先登录	可能直接完成保存

截图 o_t 是观测，状态还可能需要登录状态与任务阶段

状态决定合法动作

教学例：主页、表单和两个终态

状态	含义	合法动作
H	主页	open 打开表单
F	表单	save 保存
S / X	成功 / 失败终态	结束，本例不再执行动作

初始状态为 H，动作的名称与执行条件固定

下一状态与奖励的联合核

$p(s', r \mid s, a)$

给定 s 和 a，下一状态为 s′
且本次反馈奖励为 r 的条件概率

对所有可能的 s′ 与 r 求和，结果为 1
本课表格同时列出概率和即时净奖励

r 对应首课的 r_{t+1}，下标简写保持同一时间约定

随机转移的教学表

每步成本为 1，成功额外收益为 10

当前状态与动作	下一状态	概率	即时净奖励 r
H，open	F 表单	0.80	−1
H，open	X 失败	0.20	−1
F，save	S 成功	0.75	+9 = 10 − 1
F，save	X 失败	0.25	−1

每个状态动作对的分支概率分别和为 1

全部数值为教学假设，未运行真实 GUI 实验

单步期望奖励

$$R(F, \text{save}) = 0.75 \times 9 + 0.25 \times (-1)$$

$$= 6.5$$

$$R(H, \text{open}) = 0.8 \times (-1) + 0.2 \times (-1) = -1$$

$R(s, a)$ 是一次动作的期望奖励
G_0 是完整轨迹的折扣回报

平均即时奖励不会自动包含后续保存成功的收益

完整轨迹的期望回报

$\gamma = 0.9$，任务到达 S 或 X 后结束

轨迹	概率	折扣回报 G_0
H 到 X	0.20	-1
H 到 F 到 X	$0.80 \times 0.25 = 0.20$	$-1 + 0.9 \times (-1) = -1.9$
H 到 F 到 S	$0.80 \times 0.75 = 0.60$	$-1 + 0.9 \times 9 = 7.1$

$$\mathbb{E}[G_0] = 0.2 \times (-1) + 0.2 \times (-1.9) + 0.6 \times 7.1$$

$$= 3.68$$

路径概率和为 1；本例成功率 0.60，期望步数 1.8

任务结束与外部截断

情况	含义	建模检查
任务终止	任务本身达到成功、失败或内置时限	剩余步数或阶段可能属于状态
采集截断	采集器停止，但底层任务仍可继续	保留停止原因与截断标记

同为“停止采集”，后续目标与数据解释可能不同

先明确时限属于任务定义，还是来自外部采集器

研究任务中的状态与边界

方向	需要核查的信息与决策	首轮基线
多步 GUI	页面、权限、历史、剩余预算与合法操作	现有规划执行、监督模仿
模态路由	是否仅一次选择，是否获取新信息后再选择	固定路由、规则 成本敏感分类
SR	是否有停止或计算分配决策 状态是否在推理时可得	固定预算 SR 简单自适应策略

状态必须使用真实可得信息，评价须验证最终目标

三道理解题

1　相同截图：历史 H_1 未登录，H_2 已登录
保存结果分布不同，状态应怎样补充?

2　复算三条轨迹的概率和 G_0
$\gamma = 1$ 时，$E[G_0]$ 是多少?

3　增加重试且任务最多两步，预算要入状态吗?
采集器两步截断能否直接标为终态?

完整题目与参考答案在讲义，先自行作答

下一课与参考来源

RL-003　策略、轨迹与探索

下一课把固定动作扩展为可选择的策略
讨论动作采样如何改变轨迹分布

Sutton & Barto (2018)，第 3 章
Reinforcement Learning: An Introduction, 2nd ed.
CMU 课程托管二版教材原稿

Gymnasium 官方教程
Handling Time Limits