RL-003

策略、轨迹与探索
数据从哪里来?

2026-10-15 · 讲解约 13 分钟
学习 35～45 分钟

本课目标与前置

1　区分策略 π 与环境概率 p

2　用初态、动作与反馈概率计算轨迹概率

3　解释探索怎样改变覆盖与采集成本

前置 RL-001 回报与期望，RL-002 状态、动作和联合核

策略是动作选择规则

离散动作下，π(a | s) 给出合法动作的概率分布

形式	怎样选择动作	本课例子
随机策略 π	同一状态可按分布采样	πA(I | u) = 0.20
确定策略 μ	当前状态对应固定动作	μ(u) = T，μ(v) = I

每个状态的合法动作概率和为 1

策略概率与环境概率

概率	回答的问题	教学例子
$\pi(a \mid s)$	给定信息，智能体选哪个动作?	$\pi_A(T \mid u) = 0.80$
$p(s', r \mid s, a)$	动作执行后，环境返回什么结果?	$p(z, 9.5 \mid u, T) = 0.90$

改变策略会改变采样频率，环境反馈规律保持给定

本课用 z 表示任务终态，T/I 仅为文本/图像分支的动作名

完整轨迹的概率

$$\Pr_{\pi}(\tau) = \rho_0(s_0) \prod_t \pi(a_t \mid s_t)\, p(s_{t+1}, r_{t+1} \mid s_t, a_t)$$

ρ_0：初始状态分布，τ：完整状态、动作和奖励序列
π：动作采样概率，p：环境联合转移概率

先出现这个起点，再选这些动作，再得到这些反馈
每一步都必须满足任务的合法动作与终止规则

有限离散、时间齐次 MDP 与 Markov 策略；乘积覆盖终止前的每一步

路由环境的教学假设

每次选择一个分支后结束，正确收益 10，错误收益 0

上下文	动作	正确概率	成本	期望净奖励
u	T 文本	0.90	0.5	8.5
u	I 图像	0.95	2.0	7.5
v	T 文本	0.40	0.5	3.5
v	I 图像	0.85	2.0	6.5

净奖励 = 10 × 正确指示值 − 调用成本

u/v 在决策前可见，全部数字是假设，未运行业务实验

策略决定动作采样频率

初态分布 $\rho_0(u) = 0.60$，$\rho_0(v) = 0.40$

上下文	$\pi_A(T \mid \text{上下文})$	$\pi_A(I \mid \text{上下文})$
u	0.80	0.20
v	0.30	0.70

总体 I 调用率 = 0.6 × 0.2 + 0.4 × 0.7 = 0.40

总体频率同时依赖上下文分布与条件策略

一条轨迹的三项概率

轨迹：从 u 出发，选择 T，获得正确奖励 9.5，进入终态 z

$$\Pr\pi A(u, T, 9.5, z)$$

$$= 0.60 \times 0.80 \times 0.90 = 0.432$$

0.60：遇到 u 的概率
0.80：在 u 选择 T 的概率
0.90：给定 u、T 后获得正确结果的概率

这是一条完整路径的概率；其回报为 9.5，概率本身不是回报

策略的期望净回报

上下文	按动作概率加权	条件期望
u	0.80 × 8.5 + 0.20 × 7.5	8.3
v	0.30 × 3.5 + 0.70 × 6.5	5.6

$$E_{\pi A}[G_0] = 0.60 \times 8.3 + 0.40 \times 5.6 = 7.22$$

也可对八条完整路径按“概率 × 净奖励”求和，结果相同

探索的覆盖与成本

给定策略	I 调用率	期望成本	期望净回报
πA	0.40	1.10	7.22
μ：u 选 T，v 选 I	0.40	1.10	7.70
πU：两动作均匀采样	0.50	1.25	6.80

μ 有两格零概率，πA 与 πU 对四格均赋正概率

非零支持不保证有限日志已覆盖；随机性也不保证回报提高

行为日志与未选择的动作

记录内容	为什么需要
决策前信息与合法动作	核查输入权限，区分当时允许与不允许的选择
实际采样概率与策略版本	知道数据来自哪条行为规则及其支持范围
所选动作、结果和成本	保留真实反馈，未选动作的结果继续标未知

观察到 T 失败，不能据此给 I 标失败

记录的应是当时真实动作采样概率，不能事后编造

三个方向的探索条件

方向	需要先明确的反馈和代价	比较基线
模态路由	分支正确性、错误代价、调用成本 上下文与合法动作在选择前可见	固定分支、规则 成本敏感监督模型
多步 GUI	合法操作、任务成功和可恢复环境 错误操作、重置与采样的代价	规则执行 示范学习与既有规划
SR	是否确有迭代、停止或计算分配动作 评价时的质量与计算预算	固定预算 SR 简单自适应策略

数据分布、目标和执行权限一致，比较才有解释力

三道理解题

1　$\rho_0(u)=0.6$，$\pi A(I \mid u)=0.2$，环境正确概率0.95
完整正确路径概率多少？μ 不选 I 意味着什么?

2　复算 πA、μ、πU 的回报、I 调用率与成本
I 调用率相同，为什么回报仍可能不同?

3　只观察到 μ 选 T 后失败，能否标 I 为失败?
缺哪些覆盖与日志？怎样合法补充信息?

完整题目与参考答案在讲义，先自行作答

下一课与参考来源

RL-004 价值函数

下一课为状态和动作的后续收益建立定义
继续区分“由谁采样”与“评价什么”

Sutton & Barto，二版教材原稿
CMU 课程托管 PDF，策略定义
官方教程 OpenAI Spinning Up，Key Concepts in RL

本课数字：已知环境和给定策略的教学枚举
实际研究实验：未运行（NOT_RUN）