RL-004

价值函数：从一次结果到期望表现

2026-10-16 · 讲解约 13 分钟
学习 35～45 分钟

本课目标与前置

1　区分一次回报与价值函数的期望

2　说清 V 与 Q 各自固定了哪些条件

3　核对后续策略与剩余预算怎样影响价值

前置：RL-001 回报，RL-002 环境，RL-003 策略与轨迹概率

一次回报与期望价值

对象	它表达什么
一次回报 G_t	一条具体轨迹从时刻 t 开始获得的累计奖励
真实价值	在给定状态、后续策略与目标下，对可能轨迹求期望
价值估计	用数据或模型近似这个期望，可能存在误差

同一条件下的一次失败，不会把期望自动改成失败值

有限时域与完整状态

完整状态 = (页面 s，剩余动作数 h)

$$G_t = r_{t+1} + \gamma r_{t+2} + \dots$$

最多累计 h 个奖励，提前终止后的奖励记为 0
本课 γ = 0.9，预算耗尽也会结束任务

h 是任务内剩余预算；外部采集截断要另行记录

状态价值 V

$$V\pi_h(s) = E\pi[G_t \mid 从\ (s,h)\ 出发]$$

当前动作和后续动作都按策略 π 选择
同时对可能的环境反馈求期望

评价条件：状态、预算、环境、奖励、γ 与策略
比较数值前，先检查这些条件是否一致

$V\pi_h$ 对应讲义的 V_h^π，上标 π 标记被评价的策略

动作价值 Q

$Q\pi_h(s,a)$：先执行 a，之后按 π

从 (s,h) 出发，先指定一个合法动作 a
再对后续策略和环境产生的完整回报求期望

首动作已经给定，不再乘它被 π 选中的概率
即使 π 不会选 a，也可以定义这次先行选择的评价

$Q\pi_h$ 对应讲义的 Q_h^π，后续策略条件仍然保留

复用单步路由：从 Q 得到 V

上一课的教学环境每次只做一个动作，随后结束

上下文	Q(T 文本)	Q(I 图像)	VπA
u	8.5	7.5	8.3
v	3.5	6.5	5.6

$$V_{\pi A}(u) = 0.8 \times 8.5 + 0.2 \times 7.5 = 8.3$$

$\rho_0(u)=0.6$、$\rho_0(v)=0.4$，整体期望 $J(\pi A)=7.22$

新的两步 GUI 教学环境

γ = 0.9，初始完整状态为 (H,2)，z 为终态

页面	动作	环境结果与即时奖励	πα / πβ 概率
H 主页	open	确定到 F，r = −1	0.75 / 0.75
H 主页	stop	到 z，r = 0	0.25 / 0.25
F 表单	save	到 z：0.80 得 10，0.20 得 0	1.00 / 0.50
F 表单	cancel	到 z，r = 0	0.00 / 0.50

独立扩展例：保存不另扣成本，与 RL-002 不是同一奖励约定

相同首动作，不同后续策略

从 (H,2) 先指定 open；此时不再按 0.75 抽样首动作

后续策略	$G_0 = 8$ 的概率	$G_0 = -1$ 的概率	$Q_2(H,open)$
$\pi\alpha$	0.80	0.20	6.2
$\pi\beta$	0.40	0.60	2.6

成功路径 $G_0 = -1 + 0.9 \times 10 = 8$

其他路径 $G_0 = -1 + 0.9 \times 0 = -1$

从 H 按策略出发的价值

$$V\alpha_2(H) = 0.75 \times 6.2 + 0.25 \times 0 = 4.65$$

$$V\beta_2(H) = 0.75 \times 2.6 + 0.25 \times 0 = 1.95$$

V 从首步就遵循策略：有 0.25 的概率立即 stop
Q(H,open) 已固定首动作，评价条件不同

对同一状态的首动作求加权平均，使用全期望法则

剩余预算也是价值条件

从 H 开始	$Q\alpha_h(H,open)$	$V\alpha_h(H)$
h = 2	6.2	4.65
h = 1	−1	−0.75
h = 0	无合法动作，不定义 Q_0	0

只剩一步时，open 后预算耗尽，不会继续保存

同一页面截图不足以区分不同剩余预算

价值定义怎样用于研究任务

方向	先明确价值所条件化的信息	评价与基线
多步 GUI	任务、观测或状态、后续策略与剩余预算 真实保存结果、非法动作和操作成本	完整任务成功率与成本 规则、示范学习、已有规划
模态路由	决策前上下文、合法分支与给定奖励 单步时 Q 是净奖励期望	固定分支、规则 成本敏感监督模型
SR	先定义停止、迭代或计算分配动作 推理可得状态与质量—计算目标	固定预算 SR 简单自适应策略

已知模型中的精确价值，不等于真实系统中可靠的估计

三道理解题

1　复算路由的 VπA(u)、VπA(v) 与整体 J
一次 u、T 答错得 −0.5，是否就有 Q = −0.5?

2　h=2 先 open，按 πα / πβ 时 Q 和 V 各多少?
为什么 Q 不再乘首步 open 概率 0.75?

3　h=2 改为 h=1，Qopen 与 V 为什么改变?
外部采集截断能否直接把真实价值设为 0?

完整题目和参考答案在讲义；先列评价条件，再计算

下一课与参考来源

RL-005 Bellman 方程

下一课将价值与后继状态联系起来
本课先把期望、策略条件和预算定义清楚

Sutton & Barto，二版教材原稿，第 3.5 节
CMU 课程托管 PDF，价值函数定义
官方教程 OpenAI Spinning Up，Value Functions

本课算例：独立教学扩展与完整路径手算
真实研究实验：未运行（NOT_RUN）