RL-005

Bellman方程：把长期回报拆成一步与未来

2026-10-17 · 讲解约 13 分钟
学习 35～45 分钟

本课目标与前置

1　从回报拆分写出固定策略的期望方程

2　用边界值复算 RL-004 的 GUI 价值

3　区分策略平均与最优动作的 max

前置：RL-001 回报，RL-002 转移，RL-003 策略，RL-004 价值

回报的逐步分解

$$G_t = r_{t+1} + \gamma G_{t+1}$$

当前奖励已经计入，未来回报从下一时刻开始
γ 只折扣未来部分

成功路径：$r_1 = -1$，$r_2 = 10$，$\gamma = 0.9$
$G_1 = 10$，$G_0 = -1 + 0.9 \times 10 = 8$

有限 h：最多累计 h 个奖励，真正终止后的续值为 0

指定首动作后的 Bellman 期望

$$Q\pi_h(s,a) = \Sigma_{s',r}\, p(s',r \mid s,a) \times [r + \gamma V\pi_{h-1}(s')]$$

先固定合法动作 a，再平均下一状态与即时奖励
到达 s′ 后，后续动作继续按策略 π

边界：$V\pi_0(s) = 0$，$V\pi_h(z) = 0$

h ≥ 1；z 是终态；符号 $Q\pi_h$ 对应讲义 Q_h^π

按策略选择当前动作的期望

$$V\pi_h(s) = \Sigma_a\, \pi(a \mid s,h)\, Q\pi_h(s,a)$$

策略 π 平均当前动作
环境 p 平均动作之后的随机结果

$V\pi_h(s) = E[r + \gamma V\pi_{h-1}(s')]$
这个期望同时包含 π 与 p 的随机性

固定策略的 Bellman 期望方程评价这条策略，不替换它

沿用 RL-004 的 GUI 环境

γ = 0.9，初始 (H,2)，每个动作消耗一次真实预算

页面	合法动作	环境结果与即时奖励	πα / πβ 概率
H 主页	open	确定到 F，r = −1	0.75 / 0.75
H 主页	stop	终止，r = 0	0.25 / 0.25
F 表单	save	终止：0.8 得 10，0.2 得 0	1.00 / 0.50
F 表单	cancel	终止，r = 0	0.00 / 0.50

save 不另扣成本；预算耗尽终止，无额外罚分；全部为教学假设

从 h = 0 的边界计算 h = 1

最后一个动作之后，后续价值为 0

h = 1 的状态	动作价值	固定策略价值
F 表单	Q(save)=8，Q(cancel)=0	$V\alpha_1(F)=8$，$V\beta_1(F)=4$
H 主页	Q(open)=−1，Q(stop)=0	$V\alpha_1(H)=V\beta_1(H)=-0.75$

$$Q_1(F,save) = 0.8 \times 10 + 0.2 \times 0 = 8$$

$V_0(s)=0$；h=0 无合法动作，不要求定义 Q_0

h = 2 时的一步与未来

固定策略	$Q_2(H,\text{open})$	$V_2(H)$
π_α	$-1 + 0.9 \times 8 = 6.2$	$0.75 \times 6.2 = 4.65$
π_β	$-1 + 0.9 \times 4 = 2.6$	$0.75 \times 2.6 = 1.95$

open 的环境转移相同，后续 $V_1(F)$ 随策略改变

$Q_2(H,\text{stop})=0$；Q 已固定首动作，V 才包含首步的策略抽样

Bellman 期望与最优方程

比较项	固定策略	最优目标
当前动作	按 $\pi(a\|s,h)$ 加权平均	在合法动作中取 max
后续价值	$V\pi_{h-1}(s')$	$V^*_{h-1}(s')$
环境结果	按 p 求期望	仍按 p 求期望

$$V^*_h(s) = \max_a \sum_{s',r} p(s',r|s,a) \times [r + \gamma V^*_{h-1}(s')]$$

max 只能选择动作，不能选择随机环境中的好运结果

最优动作随剩余预算改变

完整状态	Q*(open / save)	Q*(stop / cancel)	V* 与最优动作
(F,1)	save：8	cancel：0	8，选择 save
(H,1)	open：−1	stop：0	0，选择 stop
(H,2)	open：6.2	stop：0	6.2，选择 open

π_α 的 $Q_2(H,\text{open})=6.2$，但 $V^{\pi_\alpha}_2(H)=4.65$

最优策略还须在 H,h=2 选择 open；π_α 有 0.25 概率提前 stop

方程、模型计算与学习更新

对象	本课含义	使用前提与限制
Bellman 方程	真实价值满足的一步与未来关系	状态、终止与回报约定正确
已知模型计算	对 p 的所有可能结果求和	模型准确且求和可行
数据中的价值估计	用有限数据近似未知价值	覆盖与估计误差需要另行处理

今天没有把一次样本反馈写成参数更新

γ=0.9 是本课约定；有限预算下也允许 γ=1，仍需正确边界

主要应用：多步 GUI 的续值判断

建模与检验	具体要求
状态与动作	任务、页面、权限、历史信息与剩余预算 合法点击、输入、保存、停止
奖励与反馈	真实任务结果和操作成本 执行后观测、终止原因及失败记录
数据与评价	可重置轨迹、覆盖与失败场景 成功率、错误操作率、延迟和调用成本

比较规则、示范学习与既有规划；真实实验未运行

单步路由的终止续值为 0；SR 需先定义实际的序列决策

三道理解题

1　成功路径的 G_1 与 G_0 是多少？
p 的平均与 π 的平均分别处理什么随机性？

2　从 V_0 开始，复算 α / β 的 $V_1(F)$、
$Q_2(H,open)$ 与 $V_2(H)$。Q 为何不乘 0.75？

3　求 (H,1)、(F,1)、(H,2) 的最优动作和值。
α 的 Q_2 已为 6.2，为何策略仍非最优？

先自行作答；参考答案在讲义文末与本页演讲者备注

下一单元与原始资料

RL-006：首次应用单元

把当前建模与价值概念用于研究任务
先检查决策、反馈和非 RL 基线

Sutton & Barto，第二版教材原稿，第 3 章
OpenAI Spinning Up，Bellman Equations

本课：教学假设与精确手算
实际 GUI、路由、SR 研究实验：未运行（NOT_RUN）