RL-007

复习：从任务描述到MDP与回报

2026-10-19 · 讲解约 13 分钟
学习 35～45 分钟

本课目标与前置

1　用同一任务串联第一周概念

2　用完整路径与一步关系互相核对

3　识别真实任务的反馈与比较缺口

前置：RL-001～006；本课不展开下一周的迭代更新

第一周的六个环节

单元	核心问题	衔接到哪里
RL-001	谁做决策，奖励怎样组成回报?	明确环境与起止
RL-002	状态、合法动作与后果是什么?	再定义行为规则
RL-003	策略怎样产生轨迹与覆盖?	对可能轨迹求期望
RL-004	V、Q 在哪些条件下评价?	联系当前与未来
RL-005	一步奖励与后续价值怎样连接?	核查模型与边界
RL-006	真实任务缺哪些事实与基线?	回到工程合同自查

观测、状态与两种概率

对象	它表达什么	反例或检查
观测 o	当前真正可见的信息	同截图可能有不同登录状态
完整状态	足以描述后续后果的表示	页面与剩余预算 h 都有影响
策略 π	$\pi(\text{open}\mid H,h)=0.75$	选择 open 的概率
环境 p	$p(z,10\mid F,\text{save})=0.8$	执行 save 后的成功奖励概率

π 与 p 针对不同事件，未执行动作的结果仍未知

奖励、回报与期望价值

量	固定了什么条件
即时奖励 r_{t+1}	当前动作之后的一次反馈
路径回报 G_t	一条实际轨迹从 t 开始的累计奖励
$V\pi_h(s)$	从 (s,h) 开始，首步及后续都按 π
$Q\pi_h(s,a)$	先指定合法动作 a，后续再按 π

$$G_t = r_{t+1} + \gamma G_{t+1},\quad J(\pi)=E[G_0]$$

单条成功不等于期望表现；Q 使用回报单位，可以为负或大于 1

完整列出同一 GUI 教学模型

初态固定 (H,2)，γ=0.9，每个动作消耗一次真实预算

页面	合法动作	环境结果与即时奖励	πα / πβ 概率
H 主页	open	确定到 F，r=−1	0.75 / 0.75
H 主页	stop	到 z，r=0	0.25 / 0.25
F 表单	save	到 z：0.8 得 10，0.2 得 0	1.00 / 0.50
F 表单	cancel	到 z，r=0	0.00 / 0.50

save 不另扣成本；预算耗尽无额外罚分；全部为既有教学假设

πα 的完整路径与回报

从 (H,2) 开始的结果	完整路径概率	G_0
stop	0.25	0
open 后 save 成功	0.75 × 1 × 0.80 = 0.60	8
open 后 save 失败	0.75 × 1 × 0.20 = 0.15	−1

$$V\alpha_2(H) = 0.25 \times 0 + 0.60 \times 8 - 0.15 = 4.65$$

三条路径概率和为 1；成功回报为 −1 + 0.9×10 = 8

πβ 的完整路径与回报

从 (H,2) 开始的结果	完整路径概率	G_0
stop	0.25	0
open 后 save 成功	0.75 × 0.50 × 0.80 = 0.30	8
open 后 save 失败	0.75 × 0.50 × 0.20 = 0.075	−1
open 后 cancel	0.75 × 0.50 = 0.375	−1

$$V\beta_2(H) = 0.30 \times 8 - 0.075 - 0.375 = 1.95$$

首动作条件与剩余预算

评价条件	πα	πβ
$Q_2(H,\text{open})$，首动作已指定	6.2	2.6
$V_2(H)$，首步按策略抽样	4.65	1.95
$Q_1(H,\text{open})$，无预算再保存	−1	−1
$V_1(H)$，保持原策略概率	−0.75	−0.75

h=1 最优 stop，值 0；h=2 最优 open，值 6.2

Bellman 关系中的平均与 max

$$Q\pi_h(s,a)=\Sigma_{s',r}\, p(s',r|s,a) \times [r + \gamma V\pi_{h-1}(s')]$$

$$V\pi_h(s)=\Sigma_a\, \pi(a|s,h)\, Q\pi_h(s,a)$$

$$V^*_h(s)=\max_a Q^*_h(s,a)$$

环境结果仍取平均，max 只选合法动作

$V_0(s)=0$，$V_h(z)=0$；终态或无预算时直接使用边界

GUI 工程自查：缺什么证据

自查项	真实任务需要明确的条件
信息与动作	决策前输入、合法历史、权限与可执行参数 截图充分性、初态与重置方式
奖励、反馈与期限	独立核实持久保存、奖励单位和操作成本 任务预算与终止，外部采集截断单列
数据与评价	完整成功/失败/取消轨迹，策略与执行器版本 完整任务指标、训练及推理成本、匹配基线

真实字段【待确认】；定位或保存提示不等于持久成功

三类研究方向的条件筛查

方向	进入方法比较前的条件
普通一次 SR	先比较监督重建；若研究早停或计算分配 需真实可控动作、质量成本目标和部署可见线索
单步模态路由	真实输入、标签、分支、反馈与成本【待确认】 区分全动作可信反馈与仅所选动作反馈
多步 GUI	先补可执行、可重置、可核实反馈的任务合同 与规则、示范学习及同预算规划比较

任务名称和公式都不能替代真实数据与公平对照

三道复习题

1 同截图、不同登录或预算：状态充分吗？
0.75 的 π 与 0.8 的 p 各表示什么？

2 列出两策略完整路径，核对 V、Q 与预算。
为什么一个 Q 最优仍不代表策略最优？

3 只记保存提示和成功日志，工程证据够吗？
补哪些字段、成本与公平基线？

先独立作答；分步参考答案位于讲义文末与本页备注

第一周小结与下一单元

任务条件明确，价值比较才有相同含义

疑问回链：概念 RL-001/002，概率 RL-003
首动作与预算 RL-004，Bellman RL-005
任务、反馈与基线 RL-006

RL-008：动态规划I，已知环境的策略评估

资料：Sutton & Barto 二版原稿，Spinning Up
教学手算；真实研究实验未运行（NOT_RUN）