RL-008

动态规划I：已知环境的策略评估

2026-10-21 · 讲解约 13 分钟
学习 35～45 分钟

本课目标与前置

1　写出已知模型下的固定策略期望更新

2　用 old / new 两张表手算两轮

3　解释停止原因、收敛条件与模型边界

前置：RL-007 复习；RL-004 价值条件；RL-005 Bellman 关系

策略评估的输入与输出

对象	本课承担的角色
已知模型 p	合法动作的下一状态、奖励与联合概率
固定策略 π	当前及后续的动作选择规则，评估中保持不变
目标 Vπ	同一模型、策略、折扣与预算下的期望回报
近似表 v_k	完成第 k 轮计算后得到的当前数值

用模型求期望，不采样一条轨迹，不更新行为策略

计算轮数 k 与任务预算 h

记号	含义	一轮更新时怎样变化
k	价值表已完成的计算轮数	从 k 生成 k+1，不增加真实动作
h	任务还允许执行的真实动作数	后继状态读取 h−1
$v_k(s,h)$	页面 s 与预算 h 的当前近似	同一完整状态可被反复计算
零边界	预算耗尽或真正终止	$v_k(s,0)=0$，$v_k(z,h)=0$

v_0 全零是初始化；终态和 h=0 的零值是固定边界

同步 Bellman 期望更新

$$v_{k+1}(s,h) = \Sigma_a \pi(a|s,h) \Sigma_{s',r} p(s',r|s,a) \times [r + \gamma v_k(s',h-1)]$$

外层平均策略动作，内层平均环境结果
本轮所有续值只读同一张旧表 v_k

尚未终止、h≥1；求和只含合法动作；π 始终固定

两数组同步计算的伪代码

```
v = zero_table；边界为 0
for k = 1 .. K_max:
    old = copy(v)；new = zero_table
    按上一页公式算 new，续值只从 old 读取
    Δ = max_abs_difference(new, old)
    v = new；全轮完成后才提交
    若 Δ < θ，返回 tolerance_reached
达到上限则返回 iteration_limit
```

Δ 比较整张新旧表；θ>0 是回报单位的停止阈值，不是学习率

沿用的 GUI 模型与固定 πα

γ=0.9，初态 (H,2)，每个动作消耗一步真实预算

页面	合法动作	下一页面与即时奖励	πα 概率
H 主页	open	确定到 F，r=−1	0.75
H 主页	stop	到 z，r=0	0.25
F 表单	save	到 z：0.8 得 10，0.2 得 0	1.00
F 表单	cancel	到 z，r=0	0.00

save 不另扣成本；无额外期限罚分；全部为既有教学假设

第一轮：未来仍读取零表

完整状态	v_0：旧表	v_1：第一轮新表
(H,2)	0	−0.75
(F,2)	0	8
(H,1)	0	−0.75
(F,1)	0	8
h=0 或 z	0	0

$$v_1(H,2)=0.75[-1+0.9\times 0]=-0.75$$

第二轮：后续奖励传播到 H2

完整状态	v_1：旧表	v_2：第二轮新表
(H,2)	−0.75	4.65
(F,2)	8	8
(H,1)	−0.75	−0.75
(F,1)	8	8
h=0 或 z	0	0

$$v_2(H,2)=0.75[-1+0.9\times 8]=4.65$$

全表变化与实际停止原因

轮次 k	$v_k(H,2)$	$\Delta_k = \max\lvert v_k - v_{k-1}\rvert$
1	−0.75	8
2	4.65	5.4
3：停止核查	4.65	0

θ=0.000001，K_max≥3：第三轮达到阈值

K_max=2：返回 iteration_limit

收敛直觉与适用条件

固定模型与 π，有限表格，有界奖励
0 ≤ γ < 1：一轮期望更新会收缩表间差异

$$||T_\pi u - T_\pi w||_\infty \le \gamma ||u - w||_\infty$$

γ=1 需要终止等额外条件
本例两轮精确来自两步深度，不能推广到一般任务

γ 接近 1 时可能收敛较慢；表规模与模型结果枚举也产生计算成本

主要应用：GUI 模型内固定策略评估

需要分开的检验	工程检查
计算是否正确	固定 π 和同一模型，与枚举或线性方程核对 记录初始化、同步方式、Δ、阈值及停止原因
模型是否可信	状态与合法动作、转移来源与覆盖 独立持久结果反馈、真实期限和截断
资源与真实任务评价	建模/训练与 DP 计算分开，执行成本另计 匹配任务、输入、模型、预算和非 RL 基线

真实 p、业务奖励和成本【待确认】；研究未运行

三道理解题

1 第一轮 H2 为何是 −0.75，而非 4.65？
读取同轮新值属于哪种安排？k 会改变 h 吗？

2 写两轮完整表、$\Delta_1/\Delta_2/\Delta_3$ 与停止原因。
另评估 πβ，F 与 H2 的最终值是多少？

3 Δ 很小能证明真实 GUI 改善吗？
γ=1 能照搬收缩吗？Vπ 是否意味着最优？

先独立作答；分步参考答案位于讲义文末与本页备注

下一单元与原始资料

RL-009：动态规划II，策略改进与价值迭代

本课固定 π，改变价值表
下一课再讨论怎样改变行为

Sutton & Barto 二版教材原稿，第 4.1 节
册页 74：更新式；册页 75：两数组与停止

教学计算；真实 GUI、SR、路由研究未运行（NOT_RUN）