RL-009

动态规划II：策略改进与价值迭代

2026-10-22 · 讲解约 13 分钟
学习 35～45 分钟

本课目标与前置

1　区分评估、改进、策略迭代与价值迭代

2　手算一次贪心改进和两轮同步价值迭代

3　解释保证条件、停止与真实模型边界

前置：RL-008 策略评估；RL-005 的合法动作、环境平均和有限预算

四种计算分别更新什么

计算	主要操作	目标或输出
策略评估	固定 π，按 π 平均动作	Vπ
策略改进	按精确旧 Vπ 比较合法动作	新策略 π′
策略迭代	评估、改进、重新评估	条件成立时求最优策略
价值迭代	对旧近似表作最优期望更新	逼近 V*，再提取策略

动作可以选择，环境结果仍须按概率平均

同一 GUI 模型与旧策略 πα

γ=0.9，初态 (H,2)，每个动作消耗一步；h≤2

页面	合法动作	下一页面与即时奖励	πα 概率
H 主页	open	确定到 F，r=−1	0.75
H 主页	stop	到 z，r=0	0.25
F 表单	save	到 z：0.8 得 10，0.2 得 0	1.00
F 表单	cancel	到 z，r=0	0.00

save 不另扣成本；预算耗尽无额外罚分；全部为既有教学假设

用精确旧价值做贪心改进

$$Q\pi_h(s,a) = \Sigma_{s',r}\, p(s',r|s,a) \times [r + \gamma V\pi_{h-1}(s')]$$

$$\pi'(s,h) \in \operatorname{argmax}_a Q\pi_h(s,a)$$

先指定首动作，后续评分仍使用旧策略价值
argmax 选动作，max 取数值

精确旧 Vπ 与相同任务条件下保证不差；一般不保证一次最优或处处严格改善

一次贪心改进的动作选择

完整状态	旧 $Q_{\pi\alpha}$ 的动作评分	新 π'
(H,2)	open：6.2；stop：0	open
(F,2)	save：8；cancel：0	save
(H,1)	open：−1；stop：0	stop
(F,1)	save：8；cancel：0	save

同一 H 页面，剩两步 open，剩一步 stop

改进后重新评价新策略

完整状态	旧 Vπα	重新评价的 Vπ′
(H,2)	4.65	6.2
(F,2)	8	8
(H,1)	−0.75	0
(F,1)	8	8

H2：0.8×8 + 0.2×(−1)=6.2

策略迭代与稳定的平局规则

repeat:
    Vπ = evaluate(π, p)
    π′ = stable_greedy(Vπ, p)
    若 π′ = π，返回 π 与 Vπ
    π = π′，重新评估

旧确定动作仍为最大项时保留
否则按固定顺序选最大项

精确评估的理想保证，与阈值近似或错误模型下的结果需要区分

同步价值迭代的最优更新

$$v_{k+1}(s,h) = \max_a \sum_{s',r} p(s',r|s,a) \times [r + \gamma v_k(s',h-1)]$$

只对合法动作取 max，环境结果仍平均
所有状态只读同一 old 表，再整体提交 new

$v_k(s,0)=0$，$v_k(z,h)=0$

价值迭代的两轮表格

完整状态	V_0	V_1	V_2	V_3：核查
(H,2)	0	0	6.2	6.2
(F,2)	0	8	8	8
(H,1)	0	0	0	0
(F,1)	0	8	8	8
h=0 或 z	0	0	0	0

H2：首轮 $\max\{-1,0\}=0$；次轮 $\max\{6.2,0\}=6.2$

停止后用最终表重新提取策略

检查	本例结果
全表变化 Δ_1 / Δ_2 / Δ_3	8 / 6.2 / 0
θ=0.000001，K_max≥3	第三轮 tolerance_reached
K_max=2	返回 iteration_limit
基于最终 v_2 重新评分	H2 open，H1 stop，F save

最终策略使用返回的 v_K，不能复用最后 old scores

主要应用：GUI 模型上的预算规划

需要核实的层面	真实任务的约定
状态、动作与模型	输入权限与历史、合法执行、p 来源和覆盖 奖励单位、独立持久反馈、初态和真实期限
计算与数据证据	同模型枚举或分层回代核对，保留失败/取消 策略/模型版本，未观测反事实保持未知
资源与公平对照	建模/训练、规划与真实执行成本分开 匹配输入、底层模型、预算和非 RL 基线

真实字段【待确认】；研究实验未运行（NOT_RUN）

三道理解题

1 用精确 $V^{\pi\alpha}$ 改策略，再重新评价。
为何不能把未评估零表套入同一改进保证?

2 写同步价值迭代表、Δ 与停止原因。
用最终 v_2 如何提取策略?

3 模型内 6.2 能证明真实 GUI 改善吗?
平局、近似评价和 $\gamma=1$ 各有什么条件?

先独立作答；分步参考答案位于讲义文末与本页备注

下一单元与原始资料

RL-010：Monte Carlo，从完整轨迹估计价值

模型已知时对可能后果求和
下一课转向完整采样轨迹的价值估计

Sutton & Barto 二版教材原稿，§4.2 ~ 4.4
策略改进、策略迭代、价值迭代

教学规划计算；真实 GUI、SR、路由研究未运行