RL-010

Monte Carlo：从完整轨迹估计价值

2026-10-23 · 讲解约 13 分钟
学习 35～45 分钟

本课目标与前置

1　从真正终止的完整轨迹计算回报

2　按首次访问与逐状态计数更新均值

3　解释覆盖、方差与真实日志的条件

前置：RL-008 固定策略价值；RL-009 评价与改变策略的区别

从已知模型求和到完整经验平均

比较	RL-008～009 的规划	本课 MC 预测
输入	显式环境联合核 p	固定 π 的完整经验
计算	对可能结果求期望	接受实际回报后取均值
本课目标	可评估，也可求最优	只评价旧 πα 的 Vπ
主要代价	可信模型与表内计算	完整执行、覆盖与样本波动

已知教学核只用于核对，不进入 MC 均值更新

完整回报来自同一次任务的奖励

$$G_t = r_{t+1} + \gamma r_{t+2} + \dots$$

$$G_t = r_{t+1} + \gamma G_{t+1},\ G_T = 0$$

先确认真正终止，再从最后奖励倒序累计
进入终态那一步的奖励仍计入

外部停录或网络中断：未来回报仍未知

首次访问由前向时间决定

独立教学任务：X、X、z，奖励依次 1、2，γ=1

前向位置	完整状态	该位置的 G	first-visit 接受?
t=0	X	1+2=3	是
t=1	X	2	否

仅这条 episode：first-visit 为 3，every-visit 为 2.5

先向前标记 first_index，再倒序算 G；反向首次 seen 会错取 2

每个状态有自己的均值与计数

$$\hat{V}_n(x) = [G^{(1)}(x) + \dots + G^{(n)}(x)] / n$$

$$\hat{V}_n(x) = \hat{V}_{(n-1)}(x) + [G^{(n)}(x) - \hat{V}_{(n-1)}(x)] / n$$

n = N(x)：这个状态接受的回报数
首次 n=1 直接设为 G；N=0 保持未知

一条任务没访问 x，就不更新它的 N 和 $\hat{V}$

同一 GUI 环境与固定旧策略

完整状态 x=(页面,h)，初态 H2=(H,2)，γ=0.9

页面	动作	下一页面与即时奖励	πα 概率
H	open	确定到 F，r=−1	0.75
H	stop	到 z，r=0	0.25
F	save	到 z：0.8 得 10，0.2 得 0	1.00
F	cancel	到 z，r=0	0.00

每动作消耗一步；save 无额外成本；真终止后无新奖；全部为教学假设

四条完整轨迹逐条提供回报

构造 episode	依次发生的动作与奖励	H2 的 G	F1 的 G
E1 成功	open(−1)，save(10)	8	10
E2 停止	stop(0)	0	未访问
E3 失败	open(−1)，save(0)	−1	0
E4 成功	open(−1)，save(10)	8	10

E2 不给 F1 补零；回报不再乘路径概率

逐状态增量均值与直接平均一致

处理完	N(H2)	V̂(H2)	N(F1)	V̂(F1)
E1	1	8	1	10
E2	2	4	1	10
E3	3	7/3	2	5
E4	4	15/4=3.75	3	20/3≈6.67

H1、F2：N=0，估计未知

先标首次位置，再反向累计奖励

每条固定 π 的记录：

若非真正终止，留入未完成台账，不做完整 MC 更新
向前扫描 t=0…T−1，记录每个 x 的 first_index[x]
G=0
向后扫描 t=T−1…0：
G = r[t+1] + γG
若 t=first_index[x]：
N[x] += 1
N=1 时 $\hat{V}[x]$=G，否则 $\hat{V}[x]$ += (G−$\hat{V}[x]$)/N[x]

x 使用完整状态键；N/$\hat{V}$ 跨任务保留，first_index 每条任务重建

方差缩小有抽样与覆盖条件

$$\mathrm{Var}[\hat{V}_n(x)] = \sigma_x^2 / n$$

固定 π、合适状态、独立同分布完整 episode
持续覆盖目标状态，回报方差有限

四条构造数据只演示算术
样本增加不保证当前数值每次更接近目标

同一 episode 内多次访问的回报可能相关

主要应用：固定 GUI 执行策略评价

需要核实的层面	真实任务的约定
输入、动作与反馈	完整状态与权限、合法动作、固定策略版本 奖励单位与独立持久保存验证
完整性与评价	起止、重置、任务预算、外部截断和覆盖 含失败/取消/未完成，报告 N 与波动
成本与公平对照	采集核查、存储扫描、调用等待恢复成本 直接平均核算，匹配条件的非 RL 行为基线

真实字段【待确认】；研究实验未运行（NOT_RUN）

三道理解题

1　复算 E1 ~ E4 的回报、N 和均值。
E2 后 F1 怎样变？没访问的 H1、F2 呢？

2　复算四次增量均值与独立 X 例。
为什么反向 seen 不能判断首次访问？

3　成功筛选、截断补零、混用新策略，错在哪？
真实日志、统计条件和非 RL 对照还缺什么？

先独立作答；分步参考答案位于讲义文末与本页备注

下一单元与原始资料

RL-011：TD(0)，不等任务结束也能更新

本课从完整奖励累计 G，再按状态取均值
下一课再讨论另一种更新目标与时机

Sutton & Barto 二版教材原稿，§5.1
完整经验、first-visit / every-visit 与统计条件

教学回报与均值复算；真实研究未运行