RL-011

TD(0)：不等任务结束也能更新

2026-10-24 · 讲解约 13 分钟
学习 35～45 分钟

本课目标与前置

1　区分 TD 目标、误差与步长

2　按当时的表，逐条复算七次更新

3　处理真终止、外截断和缺失后继

前置：RL-010 完整回报与数据覆盖；RL-008 固定策略、完整状态和预算

MC 与 TD 的目标和更新时间

比较	RL-010 普通 MC 预测	本课 TD(0) 预测
目标	实际完整回报 G	一步 r 加后继当前估计
最早更新	完整回报已知后	有效转移与奖励到达后
目标的表依赖	不使用后继估计值	未终止时 bootstrap
本例步长	各状态 1/N 普通均值	固定 η=0.5

共同评价固定旧 πα，无需显式 p，不改变策略

一步 TD 的目标、误差与写入

$$y_t = r_{(t+1)} + \gamma(1-d_{(t+1)})\, V_{pre}(x_{(t+1)})$$

$$\delta_t = y_t - V_{pre}(x_t)$$

$$V_{post}(x_t) = V_{pre}(x_t) + \eta_t \delta_t$$

pre / post：本次写入前后
η 是步长，d 仅标记真正任务终止

终止标记与后继有效性

转移情况	目标与记录处理
任务真正终止	d=1，y=r，保留进入终态的奖励
外截断、原任务继续	仅在真实后继有效时，d=0 并读其估计
后继缺失或语义含混	暂存并标缺失，不编造这次目标
自动重置的新初态	分开任务，不能用作旧转移后继

预定义任务预算耗尽是真终止；停录需另行判断

教学环境、旧策略与全新零表

γ=0.9，η=0.5，初态 H2；非终态 fresh V=0、N=0

页面	动作	下一页面与即时奖励	πα 概率
H	open	确定到 F，r=−1	0.75
H	stop	到 z，r=0	0.25
F	save	到 z：0.8 得 10，0.2 得 0	1.00
F	cancel	到 z，r=0	0.00

四条构造任务依次成功、停止、失败、成功；全部为教学假设

E1：后继先是初值，再得到经验

转移	目标 y	误差 δ	更新后的值
H2 open 到 F1，r=−1	−1+0.9×0=−1	−1	H2=−1/2，F1=0
F1 save 到 z，r=10	10	10	H2=−1/2，F1=5

F1 更新为 5 后，H2 仍为 −1/2

每次只写当前状态；后面的结果不自动回改前一步

七次转移的 pre、目标与 post

步 / 当前	当前 pre	后继 pre	目标 y	误差 δ	当前 post
1 / H2	0	0	−1	−1	−1/2
2 / F1	0	0	10	10	5
3 / H2	−1/2	0	0	1/2	−1/4
4 / H2	−1/4	5	7/2	15/4	13/8
5 / F1	5	0	0	−5	5/2
6 / H2	13/8	5/2	5/4	−3/8	23/16
7 / F1	5/2	0	10	15/2	25/4

E3：后继改变不会自动回写 H2

时点	本次读取或发生什么	H2	F1
第 4 步前	读取后继 F1=5	−1/4	5
第 4 步后	y=7/2，δ=15/4	13/8	5
第 5 步后	保存失败，目标为 0	13/8	5/2
第 6 步后	再次访问 H2，读取 F1=5/2	23/16	5/2

E3 的完整 G(H2)=−1，首步 TD 目标仍为 7/2

逐转移预测的短伪代码

对固定 π 的每条有效转移，按记录先后：

```
old = V[x]
真终止：target = r
否则：确认同任务后继有效
    next_old = V[x_next]
    target = r + γ next_old
δ = target − old
V[x] = old + ηδ
N[x] += 1
```

缺失或含混记录留入台账，不编目标；不使用 first-visit 过滤

初始化、覆盖与步长的含义

完整状态	处理后 V	更新 N	解释
H2	23/16=1.4375	4	七次顺序处理的结果
F1	25/4=6.25	3	尚不能确认收敛
H1	0	0	初始化，未学得真值
F2	0	0	初始化，未学得真值

固定 η=0.5 与 1/N 不同；小 δ 不证明价值准确

主要应用：GUI 过程中的价值预测

需要核实的层面	真实任务的约定
输入、动作与反馈	完整状态、合法动作、固定策略与执行器版本 真实奖励单位、独立持久状态回读
后继、边界与数据	同任务末观测、真终止、截断、重置和覆盖 保留转移顺序、失败/取消/缺失总台账
成本与公平对照	采样训练、估计存储、调用等待恢复核查成本 方法对照 MC，匹配条件的非 RL 行为基线

真实字段【待确认】；研究实验未运行（NOT_RUN）

三道理解题

1　写 y、δ 与更新式，解释 bootstrap。
η=0.5、小 δ 和初始化 0 分别说明什么？

2　复算七步 pre / post 与最终值、更新次数。
第 4、5、6 步为何不能用最终表统一重算？

3　用独立快照计算外截断与误标终止。
预算耗尽、后继丢失及真实 GUI 合同怎样处理？

先独立作答；分步参考答案位于讲义文末与本页备注

下一单元与原始资料

RL-012：MC与TD，偏差、方差与学习曲线

Sutton（1988），原始 TD 论文
相邻预测变化与增量预测的早期研究

Sutton & Barto 二版教材原稿，§6.1
一步预测、逐转移更新与 TD 误差

下一课再作统一评价；真实研究未运行