RL-012

MC与TD：偏差、方差与学习曲线

2026-10-25 · 讲解约 13 分钟
学习 35～45 分钟

本课目标与前置

1　区分实现误差、目标统计与估计器统计

2　手算 bias、variance、MSE 与一次写入

3　拟定统一预算、独立重复的评价协议

前置：RL-010 MC、RL-011 TD；固定策略、完整状态、条件期望与方差

统计对象、参照值与随机性

对象	它描述什么	随机性或解释
一次 $z-\mu$	这次实现误差	一次观察不足以确认 bias
目标 Z：G 或 Y_v	下一条目标的分布	固定状态、策略与给定快照
估计器 $\hat{V}_D(x)$	处理整份数据后的值	训练数据、历史及声明的随机因素

先固定 x、π 与 $\mu=V_\pi(x)$，再说均值、方差和误差

Bias、variance 与 MSE

$$\mathrm{Bias}_{\mu}(Z) = \mathbb{E}[Z] - \mu$$

$$\mathrm{Var}(Z) = \mathbb{E}[(Z - \mathbb{E}[Z])^2]$$

$$\mathrm{MSE}_{\mu}(Z) = \mathbb{E}[(Z - \mu)^2]$$

$$= \mathrm{Var}(Z) + \mathrm{Bias}_{\mu}(Z)^2$$

有限二阶矩、同一参照 μ；Bias 单位是回报，Var/MSE 单位是回报平方

旧策略、完整状态与冻结快照

H2=(H,2)，γ=0.9，固定旧 πα
H 以 0.75 / 0.25 选择 open / stop，F 必 save

open 得 −1 并到 F1；save 以 0.8 得 10、0.2 得 0
真终止或预算耗尽后无额外奖励

分别冻结 b=v(F1)=0、5、8，再分析下一条路径
b=5 与上一课最终值 6.25 无关

μ=Vπα(H2)=4.65；b=8 为准确后继 oracle 特例；以下均为理论枚举

三条完整路径的理论枚举

从 H2 开始的路径	概率	MC 的 G	首步 Y（b=5)
stop 到 z	1/4=0.25	0	0
open，save 成功	3/5=0.60	8	7/2
open，save 失败	3/20=0.15	−1	7/2

$$\mu = 0.60\times 8 + 0.15\times(-1) = 4.65$$

冻结后继的 TD 目标分布

$$Y = 0，概率\ 1/4$$
$$Y = -1 + 0.9b，概率\ 3/4$$

$$E[Y] = (3/4)(-1 + 0.9b)$$

$$Bias_{\mu}(Y) = 0.9 \times 0.75 \times (b - 8)$$

准确后继可令目标无偏，open / stop 仍带来波动

同一 μ 下的目标统计量

目标与冻结条件	E[Z]	Bias	Var	MSE
MC 完整 G	4.65	0	16.9275	16.9275
TD，b=0	−0.75	−5.4	0.1875	29.3475
TD，b=5	2.625	−2.025	2.296875	6.3975
TD，b=8*	4.65	0	7.2075	7.2075

* b=8 为 oracle；全部是给定条件下的理论目标统计，不是实测方法排名

一次写入 U 的统计量

共同 a=0、η=0.5；TD 后继仍冻结 b=5

$$U = (1-\eta)a + \eta Z = Z/2$$

一次写入	E[U]	Bias	Var	MSE
使用 MC G	2.325	−2.325	4.231875	9.6375
使用 TD Y，b=5	1.3125	−3.3375	0.57421875	11.713125

理论枚举；没有连续训练或算法胜负结论

拟议公平协议：数据、预算与隔离

预先固定	比较约定
目标与参数	同策略、状态、奖励、γ、初态和明确 V_0 声明 MC 1/N 与 TD η；共同常数步长另列
数据与横轴	每次两方法成对读取同一有序流，重复间独立 主横轴是累计环境转移数，记录真实更新时间
隔离与成本	对称验证调参，最终测试流独立 另报 episode、状态更新、数据重用、耗时与成本

拟议协议，尚未执行；没有经验曲线

学习曲线的纵轴与独立重复

$$RMSE_j(m) = \sqrt{0.5(\hat{V}_{j,m}(H2)-4.65)^2 + 0.5(\hat{V}_{j,m}(F1)-8)^2}$$

j：一次独立运行；m：环境步骤检查点
先算每次运行的 RMSE，再跨 K 次取均值

若使用均值 ±1SE：SE = 跨运行 SD / sqrt(K)
声明 K≥2；状态或检查点数不能充当重复数

预定评价 {H2,F1}、各权重 1/2；1SE 不是 95% 置信区间

主要应用：GUI 固定策略预测比较

需要核实的层面	真实任务的约定
状态、策略与反馈	完整状态、合法动作、固定执行器和真实奖励 独立持久状态回读，不能只靠定位或保存提示
数据、边界与评价	完整有序经验、真终止/截断/后继及重置 固定评价范围，覆盖与缺失、独立测试和重复
资源与公平对照	采样训练、调参、推理存储和执行核查成本 MC/TD 是方法对照，非 RL 行为基线另列

真实字段【待确认】；研究实验未运行（NOT_RUN）

三道理解题

1 G=8 是否证明有偏？目标与一次 U 有何不同？
准确后继与随机历史怎样改变结论？

2 复算目标四行表与共同 a=0、η=0.5 的 U。
MSE 排序翻转能证明哪种算法总更好吗？

3 审查单种子、更新横轴、状态当重复的曲线。
还缺哪些测试隔离、反馈、覆盖和成本合同？

先独立作答；分步参考答案位于讲义文末与本页备注

下一单元与原始资料

RL-013：应用，在小型任务里比较价值估计方法

Sutton & Barto 二版教材原稿，§6.2
在线预测、特定随机游走比较及条件

Sutton（1988），§3.1 ~ 3.2 选页
后继误差、状态条件与原始比较设置

本课只有精确枚举与拟议协议，没有经验曲线