RL-013

应用：
在小型任务里比较价值估计方法

2026-10-26 · 讲解约 13 分钟
学习 30～45 分钟

本课目标与前置

1　区分方法输入、四种编号与预算单位

2　按环境检查点复算三种估计与误差

3　识别步长混杂，具体化后续比较协议

前置：RL-008～012 的固定策略、完整回报、自举与评价合同

信息层级与比较方案

方案	使用的信息与目标	更新时间或步长
DP 模型参考	完整 p、旧 πα 的模型期望	全表同步 k 轮
MC 1/N	已完整任务的实际 G	逐状态普通均值
MC η=0.5	同样等待完整 G	共同常数步长对照
TD η=0.5	一步 r 加后继当前估计	有效转移到达后

k 计计算，m 计环境，h 计预算，N 计状态更新

固定旧策略与教学 GUI 模型

完整状态 x=(页面,h)，初态 H2，γ=0.9，每动作消耗一步

页面	动作	下一页面与即时奖励	πα 概率
H	open	确定到 F，r=−1	0.75
H	stop	到 z，r=0	0.25
F	save	到 z：0.8 得 10，0.2 得 0	1.00
F	cancel	到 z，r=0	0.00

所有表重新 V0=0、N=0；表跨任务保留；save 无额外成本，结束后无额外奖罚

七条固定记录与任务完成点

m	任务	新到达的转移	r	真终止 d
1	E1	H2 open 到 F1	−1	0
2	E1	F1 save 到 z	10	1
3	E2	H2 stop 到 z	0	1
4	E3	H2 open 到 F1	−1	0
5	E3	F1 save 到 z	0	1
6	E4	H2 open 到 F1	−1	0
7	E4	F1 save 到 z	10	1

完成点 m=2、3、5、7；提前指定的 fixture（固定核对样例），不是随机采集

目标、步长与允许的写入

MC：$N_{new}(x) = N_{old}(x) + 1$

$V_{new}(x) = V_{old}(x) + \eta[G - V_{old}(x)]$
$\eta = 1/N_{new}(x)$ 或 1/2，只在完整 G 到达后更新

TD：$y = r + \gamma(1-d)V_{pre}(x_{next})$

$V_{post}(x) = V_{pre}(x) + 0.5[y - V_{pre}(x)]$

MC 本样例每个完整状态每任务仅访问一次，first-visit 与 every-visit 相同

DP：完整模型下的独立参考

计算 k	H2	F2	H1	F1	全表 Δ_k
0 初表	0	0	0	0	不适用
1	−0.75	8	−0.75	8	8
2	4.65	8	−0.75	8	5.4
3 核查	4.65	8	−0.75	8	0

k=2 已精确，k=3 才观察到不变；k 不是环境 m

MC 1/N：完整任务到达后更新

m	已完成任务	V(H2)	V(F1)	N(H2),N(F1)
0	0	0 初始	0 初始	0,0
1	0	0 初始	0 初始	0,0
2	1	8	10	1,1
3	2	4	10	2,1
4	2	4	10	2,1
5	3	7/3	5	3,2
6	3	7/3	5	3,2
7	4	15/4	20/3	4,3

共同 η=0.5：MC 与 TD 的逐步表

m	MC.5：H2	MC.5：F1	TD.5：H2	TD.5：F1
0	0	0	0	0
1	0	0	−1/2	0
2	4	5	−1/2	5
3	2	5	−1/4	5
4	2	5	13/8	5
5	1/2	5/2	13/8	5/2
6	1/2	5/2	23/16	5/2
7	17/4	25/4	23/16	25/4

固定样例的平方误差 L

$$L_m = 0.5[V_m(H2)-4.65]^2 + 0.5[V_m(F1)-8]^2,\ R_m = \sqrt{L_m}$$

m=7 方法	H2	F1	固定样例 L_7
MC 1/N	15/4	20/3	2329/1800 ≈ 1.293889
MC η=.5	17/4	25/4	1289/800 = 1.61125
TD η=.5	23/16	25/4	85649/12800 = 6.691328125

预定 H2/F1 各权重 1/2；L 非统计 MSE，R 单位为回报；未产生经验曲线

拟议比较协议：具体预算与隔离

预先固定	计划设置
独立与配对	K=20 条独立测试流，每流最多 200 环境转移 同一流内三方法读取相同有序记录
检查与参数	m={0,25,50,100,200}；中途不强终止或补 G 常步长调优仅用验证流，候选 {0.1,0.25,0.5}
指标与成本	每运行先算 R=sqrt(L)，再跨流均值与 1SE 保存覆盖、缺失、重用、计算和模型获取成本

拟议协议尚未执行；没有随机流、种子清单或曲线

主要应用：真实 GUI 的比较合同

需要核实的层面	真实任务的约定
状态、策略与反馈	完整状态、合法动作、固定执行器与真实奖励 独立持久状态回读，定位或保存提示不足
数据、边界与评价	有序转移、完整任务、有效后继与重置 预定范围、独立预测测试、覆盖和未完台账
资源与公平对照	模型获取、采样训练、推理存储和执行费用 三经验方法、DP参考、非 RL 行为基线分开

真实字段【待确认】；研究实验未运行（NOT_RUN）

三道理解题

1 DP 与经验方法知道什么？k、m、h、N 各计什么？
m=1 的 MC 与 TD，m=3 的 stop 怎样处理？

2 复算 m=2、5、7 及 MC.5、TD 的关键更新。
三个 L_7 怎样算？同 η 控制了哪些差异？

3 重放 20 遍是否是独立实验？DP 是否零成本？
如何修正曲线、测试、反馈与真实 GUI 合同？

先独立作答；分步参考答案位于讲义文末与本页备注

下一单元与原始资料

RL-014：复习：一张表看懂DP、MC与TD

Sutton & Barto 二版教材原稿
§4.1、§5.1、§6.1 ~ 6.2

固定策略评估、完整经验与一步自举
同一测试记录的计数、更新及比较边界

固定记录精确复算；随机实验与真实研究未运行