RL-014

复习：一张表看懂DP、MC与TD

2026-10-27 · 讲解约 13 分钟
学习 30～45 分钟

第二周知识地图与复习目标

复述信息来源，独立核对关键写入，并审查结论的条件

稳定单元	本周问题	条件自查入口
RL-008	已知模型的固定策略评估	old/new、k/h、停止原因
RL-009	策略改进与价值迭代	π 与 π′、平均与 max
RL-010	完整回报 MC	首次访问、G、每状态 N
RL-011	一步自举 TD(0)	pre/post、δ、有效后继
RL-012	偏差、方差与学习曲线	目标、估计器与随机性
RL-013	小任务中的比较合同	信息、步长、检查点与成本

DP、MC、TD 信息表：目标与时机

比较维度	DP	MC	TD(0)
主要信息	完整联合核 p 与固定策略 π	完整任务的 有序真实记录	有效一步转移 与真实后继
更新目标	模型期望 r+γv_old(x′)	完整实际 G 汇总真实奖励	一步采样 r+γ(1−d)V_pre(x′)
Bootstrap	有，借后继旧值	无，倒序 G 仍只用实际奖励	有，借后继估计
最早更新	模型给定后计算	任务真正结束后	有效一步到达后

共同目标：Vπ(x)，从完整状态 x 开始持续按固定 π 的折扣回报期望

DP、MC、TD 信息表：顺序与代价

比较维度	DP	MC	TD(0)
更新顺序	整轮只读 old 全轮提交 new	先标前向首次 再由完整 G 更新	每次读 pre 只写当前状态
初始化	模型可算合法 未采到的状态	N=0 没有均值 初值仍需标明	显式初值可自举 未访仍须标明
覆盖与风险	核覆盖和误差 计算域与残差	完整回报、相关 筛选与状态覆盖	状态充分、后继 边界、步长、覆盖
主要成本	模型获取核验 全表遍历和内存	等任务真正结束 缓冲、反馈与回报	采集有效转移 反馈、读取与更新

k：DP 计算轮次　m：环境转移　h：剩余动作预算　N：方法/状态更新数

固定策略预测与策略改进

今天的经验仍来自旧 πα，评价目标随策略版本明确

策略	H2 / H1 的行为	模型内 V(H2)
旧 πα	在 H 按 .75/.25 选 open/stop 在 F 必 save	4.65
RL-009 的 π′	H2 选 open，H1 选 stop 在 F 选 save	6.2

4.65 与 6.2 评价不同策略，差 1.55 仅为教学回报

两步复核的固定 GUI 合同

完整状态 x=(页面,h)，初态 H2，γ=.9，每个动作消耗一步

页面	动作	后继与即时奖励	旧 πα
H	open	确定到 F，r=−1	.75
H	stop	到 z，r=0	.25
F	save	到 z：.8 得 10，.2 得 0	1
F	cancel	到 z，r=0	0

只取人为指定 E1 成功记录，重新 V0=0、N=0

m=1：一步到达，完整回报尚未到达

H2 open，r=−1，到 F1，d=0；preH2=0，preF1=0

方案	此时允许的信息与写入	post(H2,F1)
MC 1/N	等待完整 G，N 仍为 0,0	0,0（初始）
MC η=.5	等待完整 G，N 仍为 0,0	0,0（初始）
TD η=.5	y=−1+.9×0=−1 δ=−1，H2 写入 −1/2	−1/2,0

已知下一页会成功，不给当前经验更新提前读未来

m=2：任务完成，方法写入仍不同

F1 save，r=10，到 z，d=1；完整 G(F1)=10，G(H2)=8

方案	当前目标与写入	post(H2,F1)
MC 1/N	首次 N=1，权重 1	8,10
MC η=.5	从零向完整 G 移一半	4,5
TD η=.5	只更新 F1：y=10，δ=10	−1/2,5

最终 N 均为 1,1；F1 变成 5 后，H2 保留 −1/2

DP 参考：计算 k 与环境 m 分开

DP 轮次 k	H2	F1	全域 Δ_k
0 初表	0	0	不适用
1	−.75	8	8
2	4.65	8	5.4
3 停止核查	4.65	8	0

全域 H2/F2/H1/F1；第二轮已精确，第三轮观察不变

统计对象与固定记录误差

对象	需要说明的参照与随机性	支持的结论范围
实际 G / 目标 Y	一次实现、完整抽样条件 或冻结后继快照	单次差值不能证明 bias
处理数据后的 $\hat{V}$	随机历史、初值与步长 有限二阶矩及同一参照 μ	MSE=Var+Bias² 需条件
固定 fixture 的 L	一份指定记录、预定状态权重 没有跨随机数据取期望	仅该记录的平方误差

低目标方差、低 δ 或较小 L，均不足以证明总体更优

边界与公平比较的复核条件

层面	复核约定
终止与数据	真结束保留当步奖励；外部截断先核原任务未来 有效真实后继、缺失台账及失败/取消均保留
预算与评价	同流方法配对、不同运行独立；主轴环境 m 预定状态权重，另报覆盖、更新、重用与总成本
调参与测试	验证选参；测试按既定方案读已发生前缀更新 评价真值不进经验更新；1SE 不当作 95%CI

20 条流与 200 转移仍是预案，随机曲线未运行

主要应用：固定 GUI 执行器的风险预测

合同层面	真实系统的十二项字段
任务与策略	观测/状态、合法动作、固定数据策略、奖励单位 可信持久反馈、后继与时间边界
数据与资源	初态重置、完整数据与覆盖、评价指标 数据/训练/建模费用、推理/存储/执行费用
方法与行为对照	MC/TD 与 DP 模型参考作为估计方法 固定流程、监督定位加流程、示范作为行为对照

十二项真实字段【待确认】；研究假设未运行 NOT_RUN

三道理解题与条件自查

1　用信息表解释目标、bootstrap 与更新时间。
k、m、h、N 及 4.65 / 6.2 分别指什么?

2　复算 E1 两步的目标、δ、写入和最终 N。
DP 的三轮与两条经验是否同一种预算?

3　审查零填充、截断、独立运行和指标声明。
选择两项不能独立说明的问题，给出回查动作。

先自行作答；讲义文末及本页备注提供参考答案，不据材料存在判断掌握

下一单元与原始资料

RL-015：SARSA：沿当前行为策略学习动作价值

Sutton & Barto 第二版教材原稿
§4.1 ~ 4.2、§5.1、§6.1 ~ 6.2

本周六课资料与条件自查：讲义第 5 节
复习按问题回查，下一课仅预告题名

已发表方法与指定算术已整理；真实研究未运行