RL-015

SARSA：沿当前行为策略学习动作价值

2026-10-28 · 讲解约 13 分钟
学习 30～45 分钟

本课目标与前置

1　解释 q_pi、当前估计表 Q 与实际回报 G

2　计算 ε 概率、目标、误差与一次 Q 写入

3　沿用实际下一动作，并核对终止和数据条件

前置 RL-014；动作价值回查 RL-005，TD 边界回查 RL-011，改进条件回查 RL-009

从固定策略 q_pi 到控制中的 Q

对象	含义	本课需要区分
q_pi(x,a)	先执行合法 a，之后持续按 π 所得折扣回报的期望	固定策略的真实期望目标
Q(x,a)	学习者当前的估计表 初始数也可以只是猜测	一次写入后并未精确评价新策略
一次 G	这条真实轨迹实现的回报	与期望或自举目标可以不同

完整键 x=(page,h) 加合法动作 a；H2 与 H1 分开

ε-greedy 的合法动作概率

以 1−ε 在最大动作中均匀选，以 ε 在全部合法动作中均匀选

合法动作情形，ε=.2	最大动作概率	其他合法动作概率
2 个，唯一最大	.8+.2/2=.9	.1
2 个，都并列最大	各 .5	无
只有 1 个	1	无

探索分支仍可能选中贪心动作；非法动作概率为 0

五个事件与同一条动作链

S、A、R、S、A：当前动作已执行，下一动作已选定

当前 x	当前 a	r	后继 x′	已选 a′
H2	open	−1	F1	cancel

用 Q_pre(x′,a′) 更新当前项，下一次执行同一个 a′

SARSA 的目标、误差与单项写入

未终止：$y = r + \gamma\, Q_{pre}(x',a')$
真终止：$y = r$，不再抽下一动作

$$\delta = y - Q_{pre}(x,a)$$

$$Q_{post}(x,a) = Q_{pre}(x,a) + \alpha\delta$$

pre/post 为这一次写入前后；先算目标与误差，再只写当前状态动作对

可检查的动作携带顺序

观察完整 x，按 ε-greedy 选一次 a
执行 a，读取 r、真实 x′、真终止 d
old = Q(x,a)
若真终止：target = r，不选下一动作
否则：核对有效后继与 mask，再选一次 a′
　　target = r + γ Q_pre(x′,a′)
Q(x,a) = old + α(target−old)，记录 pre/post 与 N
若真终止则结束本任务
否则沿用 x=x′、a=a′，进入下一次执行

概念伪代码未运行；缺失后继或未知 mask 暂停，采集暂停保留待执行动作

教学环境与全新 Q 初表

同一 GUI 核，新的 ε-greedy 行为；γ=.9，α=.5，ε=.2

完整状态	合法动作	初始 Q	初始 N
H2	open	1	0
H2	stop	0	0
F1	save	4	0
F1	cancel	−2	0

人为指定 open 后选 cancel；下一步执行同一 cancel

第一次写入：已选 cancel，更新 open

H2 执行 open，r=−1 到 F1，d=0；下一动作已选 cancel

本次量	更新前计算与结果
当前项 pre	Q(H2,open)=1
已选后继项 pre	Q(F1,cancel)=−2
目标 y	−1+.9×(−2)=−2.8
误差 δ	−2.8−1=−3.8
当前项 post	1+.5×(−3.8)=−.9

只写 H2,open；F 表未动，cancel 已保存等待执行

第二次写入：同一 cancel，真终止

执行已保存 cancel，r=0 到 z；无下一动作，y=0

状态动作	最终 Q	最终 N
H2,open	−.9	1
H2,stop	0	0
F1,save	4	0
F1,cancel	−1	1

Fcancel：−2 + .5×[0−(−2)] = −1；H 不自动回改

从价值预测到控制：新增条件与代价

比较维度	固定策略预测	本课 SARSA 控制
估计与行为	π 预先给定，预测 V 或 q_pi	Q 更新参与后续动作分布
经验合同	奖励、真实后继与结束规则	另需当前/下一动作、mask、策略版本
覆盖与成本	数据和 bootstrap 已需核验	探索交互、动作空间与变化策略更复杂

固定 α=.5、ε=.2 与两步记录不构成最优或收敛证据

主要应用：多步 GUI 任务控制

真实合同层面	研究前必须核对
状态、行为与反馈	完整状态/预算、合法动作、Q/ε/平局/版本 真实奖励单位、独立结果反馈、结束与后继
数据、评价与资源	初态重置、顺序五事件/覆盖/缺失 评价策略与指标、采集训练及推理执行成本
方法与非 RL 对照	先验证动作链与算术；固定流程、监督定位加流程 或示范行为对照匹配输入、权限、预算与成功判据

十二项真实字段【待确认】；采样、训练及性能 NOT_RUN

三道理解题

1　两个合法动作 Q=4、−2，ε=.2，各概率多少？
平局、单合法及更新后重抽动作怎样处理？

2　复算 cancel 主轨迹的两次 pre、y、δ、post 和 N。
实际 G 是多少？独立 save 反事实能否合入主表？

3　外截断后只剩 reset 图，能否补旧目标？
给出续接条件、真实合同及一个非 RL 行为对照。

先独立作答；讲义文末与本页备注提供分步参考答案

下一单元与原始资料

RL-016：Q-learning：用贪心目标学习控制

Sutton & Barto 第二版教材
§2.2：ε-greedy，册页 27～28
§6.4：SARSA 式 6.7 与动作携带，册页 129～130

本课只沿实际下一动作更新
下一课仅预告不同控制目标，不提前换算法

教学算术已复核；真实采样、训练和 GUI 性能未运行