RL-016

Q-learning：用贪心目标学习控制

2026-10-31 · 讲解约 13 分钟
学习 30～45 分钟

本课目标与学习对象

1　区分 q*、当前 Q、一步目标 y 与实际 G

2　用合法 pre 表计算 max、误差与单项写入

3　核对行为、截断、覆盖与真实 GUI 条件

前置 RL-015：动作价值、ε-greedy、pre/post 与真终止

实际行为与贪心目标

比较对象	本例采用的规则	F1 的具体内容
行为策略	按当前 Q 的 ε-greedy 执行动作	save .9，cancel .1 人为指定实际 cancel
目标规则	读取后继合法 Q_pre 最大值	max(4,−2)=4 由 save 的估计提供
更新输入	真实当前动作、r、后继与 mask	无需下一行为动作 a′ 不虚构 save 的奖励

目标使用估计 4，实际下一步仍执行 cancel

Q-learning 的目标与单项更新

未终止：$y = r + \gamma \max_{legal} Q_{pre}(x', u)$
真终止：$y = r$，不取后继最大值

$$\delta = y - Q_{pre}(x,a)$$

$$Q_{post}(x,a) = Q_{pre}(x,a) + \alpha\delta$$

先从同一 pre 表读当前项与后继最大值，再只写当前状态动作对

合法动作、探索与平局

ε=.2，探索分支也会选到当前最大动作

合法动作与 Q 情形	行为概率	目标 max 值
save 4，cancel −2	save .9，cancel .1	4
两个合法值都为 4	各 .5	仍为 4
仅一个合法动作	该动作概率 1	读取它的 pre 值

非法动作排除；未知或非终止空 mask 先保留异常

教学环境与独立 fresh Q

γ=.9，α=.5，ε=.2；完整状态 (page,h)，h≤2

状态动作	初始 Q	初始 N
H2,open	1	0
H2,stop	0	0
F1,save	4	0
F1,cancel	−2	0

沿用 015 初表，重新开始；不继承其最终估计

第一次写入：后继合法最大值

实际 H2 open，r=−1 到 F1，d=0；max 读取 save 的估计

本次量	同一 pre 表计算
当前项 pre	Q(H2,open)=1
后继合法最大值	max(4,−2)=4
目标 y	−1+.9×4=2.6
误差 δ	2.6−1=1.6
当前项 post	1+.5×1.6=1.8

只写 H2,open，N=1；F 两项尚未更新

独立同 pre 对照：SARSA 与 Q-learning

同一初表、同一 open 转移，实际下一动作都取 cancel

第一步的量	Q-learning	SARSA 独立对照
读取的后继项	max(4,−2)=4	Q_pre(F1,cancel)=−2
目标 y	2.6	−2.8
误差 δ	1.6	−3.8
H2,open 的 post	1.8	−.9

使用两张相同初表分别计算，不把两次结果顺序写入

第二次写入与最终教学表

实际执行 cancel，r=0 到 z；真终止目标直接为 0

状态动作	最终 Q	N
H2,open	1.8	1
H2,stop	0	0
F1,save	4	0
F1,cancel	−1	1

Fcancel：−2 + .5×[0−(−2)] = −1；H 不自动回写

一步更新的可检查顺序

观察完整 x，核对当前合法 mask，按行为选 a
执行 a，读取实际 r、原任务 x′、真终止 d
保存 Q_pre，old=Q_pre(x,a)
真终止：target=r，不取后继 max
否则：后继或 mask 无效就记录并退出，不写 Q/N
　　有效时 target=r+γ max_legal Q_pre(x′,u)
Q(x,a)=old+α(target−old)，记录 N 与日志
真终止则结束，否则 x=x′
下一循环另按行为选择实际动作

概念伪代码未运行；Q-learning 当前目标无需预先选定下一行为动作

终止、截断与收敛条件

情况	本课的处理
原任务真终止或任务 h=0	y=r，不访问空动作表
原任务继续，旧 x′ 与 mask 有效	可构 pre max；无需 a′ 或实际续接
旧后继或 mask 缺失、只有 reset 图	记录原因，跳过该 Q/N 写入

固定 α=.5、两步人工轨迹不构成收敛或最优证据

主要应用：多步 GUI 控制

真实合同层面	需要核对的字段
状态、行为与反馈	完整状态与预算、合法 mask、行为/目标版本 奖励单位、独立结果反馈、终止与外部截断
数据、评价与资源	初态与重置、真实转移及覆盖 评价策略、指标、采集训练与推理执行成本
方法与非 RL 对照	SARSA 可作方法比较 固定流程、监督定位加流程、示范行为对照

十二项真实字段【待确认】；实际研究 NOT_RUN

三道理解题

1 F1 的 save=4、cancel=−2，行为选 cancel
两种目标分别读什么？平局时值与动作如何区分？

2 复算 Q-learning 两次写入、最终 Q/N 和实际 G
同 pre SARSA 能否顺序写入同一主表？

3 外部截断没有 a′，但旧 x′ 与 mask 有效，能否更新？
若仅有 reset 图怎么办？给合同与非 RL 对照

先独立作答；讲义文末与本页备注提供分步参考答案

下一单元与原始来源

RL-017 探索策略：ε-greedy的代价与覆盖

Sutton & Barto 第二版 §6.5
式 6.8 与 Q-learning 伪代码，册页 131～132

Watkins & Dayan，1992
Technical Note: Q-Learning，实读 279～282 页

机制来自原始资料；两步人工轨迹及真实研究边界见备注