RL-017

# 探索策略：ε-greedy的代价与覆盖

2026-11-01 · 讲解约 13 分钟
学习 30～45 分钟

# 本课目标与三个概率层次

1　计算合法动作、平局与最大动作的选择概率

2　区分条件选择、任务路径与有限覆盖机会

3　核对行为成本、退火条件与真实应用合同

前置 RL-016；合法动作与 ε-greedy 回查 RL-015

# ε-greedy 的全合法均匀探索

**以 1−ε 在合法最大动作中均匀选**
**以 ε 在全部合法动作中均匀选**

$$b_\varepsilon(a|x) = \varepsilon/k + (1-\varepsilon)/m \times I[a \in B(x)]$$

**探索分支也可能选中当前贪心动作**

k 为合法动作数，m 为最大动作数；平局采用均匀规则

# 唯一最大、并列最大与单合法

| 合法动作 k，最大动作 m | ε=.2 时每个最大动作 | 每个其他动作 |
|---|---|---|
| k=2，m=1 | .8+.2/2=.9 | .1 |
| k=2，m=2 | .8/2+.2/2=.5 | 无 |
| k=4，m=2 | .8/2+.2/4=.45 | .05 |
| k=1，m=1 | 1 | 无 |

**先确定合法 mask，未知或非终止空集合先保留异常**

# GUI 主例：冻结 Q 与独立任务

每任务从 H2 开始，h≤2，γ=.9；整个主例不更新 Q

| 完整状态 | 合法动作与冻结 Q | 当前唯一贪心 |
| --- | --- | --- |
| H2 | open=1，stop=0 | open |
| F1 | save=4，cancel=−2 | save |

**固定 ε 时 g=1−ε/2；非贪心动作概率 ε/2**

# ε=.2 的四条完整路径

| 从 H2 开始的路径 | 路径概率 | 完整 G | 动作数 L |
|---|---|---|---|
| stop | .1 | 0 | 1 |
| open，save，成功 | .648 | 8 | 2 |
| open，save，失败 | .162 | −1 | 2 |
| open，cancel | .09 | −1 | 2 |

**成功：.9×.9×.8=.648；cancel：.9×.1=.09**

# 条件选择与整任务访问机会

| 状态动作对 | 已到该状态后的概率 | 从 H2 起每任务访问概率 |
| --- | --- | --- |
| H2,open | .9 | .9 |
| H2,stop | .1 | .1 |
| F1,save | .9 | .9×.9=.81 |
| F1,cancel | .1 | .9×.1=.09 |

**状态动作访问事件可以同任务发生，概率不必合计为 1**

# 十个任务的有限覆盖概率

指定 F1,cancel：每任务 p=.09，任务数 M=10

期望访问次数 E[C_10] = 10×.09 = .9
零次概率 P(C_10=0) = .91^10 ≈ .389416

至少一次概率 ≈ .610584
期望 .9 次与“保证一次”含义不同

# 行为回报、成功与动作步数

| 冻结 Q 与同一已知教学核 | ε=0 | ε=.2 | ε=1 |
|---|---|---|---|
| 每页贪心概率 g | 1 | .9 | .5 |
| 行为期望回报 E[G] | 6.2 | 4.932 | 1.3 |
| 教学成功概率 | .8 | .648 | .2 |
| 期望动作数 E[L] | 2 | 1.9 | 1.5 |

**提前退出可减少步骤，也可能减少成功与回报**

# 退火反例：需要连续两次稀有选择

独立 X/Y 纯采集模型，固定排序、两合法动作，所有奖励 0

| 状态 | 唯一贪心动作 | 非贪心动作与后果 |
| --- | --- | --- |
| X | exit，终止 | enter，到 Y |
| Y | exit，终止 | probe，终止；指定覆盖对 |

**全局任务 n 用 $\varepsilon_n = 1/n$；$p_n = 1/(4n^2)$**

**曾覆盖概率 ≤ .5；从未覆盖概率 ≥ .5**

# 行为分布与同快照 Q-learning 目标

| 对象 | 改变 ε 时应怎样理解 |
| --- | --- |
| 同一冻结 Q、mask 和 open 转移 | 合法 max 仍为 4，单次目标仍为 2.6 |
| 实际探索行为 | 动作分布、到达机会、回报与成本可改变 |
| 真实开始学习后 | 数据改变会影响 Q，后续目标不能继续当常数 |

**本课计算行为回报期望，不引入下一单元的新目标**

# 主要应用：多步 GUI 覆盖规划

| 真实合同层面 | 研究前核对的内容 |
| --- | --- |
| 状态、动作与反馈 | 完整状态、初态可达性、合法 mask、ε 计时/版本<br>奖励业务成本、独立结果反馈、真实终止与截断 |
| 数据、评价与费用 | 机会分母、路径、未到达/未尝试/缺失记录<br>指标与评价策略、采集训练及推理执行成本 |
| 方法与非 RL 对照 | 探索计划属于方法比较<br>固定流程、监督定位加流程或示范行为对照 |

**十二项业务合同【待确认】；真实研究 NOT_RUN**

# 三道理解题

1　四合法、双最大、ε=.2，各动作概率多少？
探索分支与非贪心事件有什么区别？

2　复算四路径、行为回报、步骤及十任务覆盖
.1、.09、.9 次和 .610584 分别指什么？

3　退火反例为什么有 $p_n=1/(4n^2)$？
.5 是什么界？真实应用还缺哪些合同和对照？

独立作答后核对讲义文末答案；详细推导也在本页备注

# 下一单元与原始参考来源

## RL-018 Expected SARSA与Double Q：改进目标估计

Sutton & Barto 第二版
§2.2 及 §6.4 ~ 6.5 的选择规则与覆盖条件

Watkins & Dayan，1992，Technical Note: Q-Learning
原文 280 ~ 282 页的表格与访问前提

理论枚举与数学反例；实际研究未运行