RL-018

Expected SARSA与Double Q：改进目标估计

2026-11-02 · 讲解约 13 分钟
学习 30～45 分钟

两个问题，三个学习目标

动作抽样：后继给定，目标仍随下一动作变化

最大化偏差：用同组噪声既选最大又评价

1 算清 ES 目标与条件方差
2 区分 Double 选表、评价表与写入表
3 核对独立性、边界和真实应用证据

前置 RL-015 / 016 / 017；完整收敛条件留给 RL-019

Expected SARSA：对下一动作求和

$$\bar{Q}_{\pi}(x') = \sum_{\text{合法 } u} \pi(u|x')\, Q_{\text{pre}}(x',u)$$

真终止：$y = r$
非终止：$y = r + \gamma \bar{Q}_{\pi}(x')$

$$\delta = y - Q_{\text{pre}}(x,a)$$
$$Q_{\text{post}}(x,a) = Q_{\text{pre}}(x,a) + \alpha\delta$$

本例 π=b；一般 ES 可指定与行为不同的目标 π

ES 主例：新建教学表与一次写入

H2 open，r=−1 → F1；γ=.9，α=.5，ε=.2，π=b

完整状态	合法动作与 Q_pre	后继目标概率
H2	open=1，stop=0	本条已执行 open
F1	save=4，cancel=−2	.9 / .1

后继均值 .9×4+.1×(−2)=3.4

y=2.06，δ=1.06，Hopen 的 post=1.53

同原始 pre 的三份独立对照

量	Expected SARSA	Q-learning	SARSA，已选 cancel
后继项	3.4	4	−2
目标 y	2.06	2.6	−2.8
δ，当前 pre=1	1.06	1.6	−3.8
post，α=.5	1.53	1.8	−.9

独立同 pre，不串写；目标大小不能作为算法排名

只随机下一动作：条件方差

固定 C：r=−1、x′=F1、Q_pre=(4,−2)、π=(.9,.1)

条件下的目标	取值 / 概率	均值	条件方差
SARSA	2.6 / .9；−2.8 / .1	2.06	2.6244
Expected SARSA	固定 2.06	2.06	0

奖励、转移、训练快照与估计误差仍可变化

最大化偏差：独立的噪声枚举

两动作真值均 0；X1、X2 相互独立，±1 各半

X1	X2	联合概率	max(X1,X2)
1	1	1/4	1
1	−1	1/4	1
−1	1	1/4	1
−1	−1	1/4	−1

E[max]=.5；独立 Z 评选中索引：0；复制 Z=X：.5

Double Q：选择、评价、写入分开

A 支：a* = argmax[合法 u] QA_pre(x′,u)
yA = r + γ QB_pre(x′,a*)；只写 QA

B 支：b* = argmax[合法 u] QB_pre(x′,u)
yB = r + γ QA_pre(x′,b*)；只写 QB

只取一支；另一表不动；评价同一个已选索引

行为可用 QA+QB 的 ε-greedy；行为选动作与更新分支分开

Double 主例：另起一对 pre 表

同观察 H2 open，r=−1 → F1；与 ES 的写入完全分开

状态动作	QA_pre	QB_pre	行为用两表和
H2,open	1	0	1
H2,stop	0	0	0
F1,save	4	1	5
F1,cancel	−2	5	3

F1 行为：save .9 / cancel .1；不是 A/B 支概率

A 支写入；B 支另作同 pre 核对

步骤	主演示：A 支	独立对称：B 支
选择动作	QA 选 save=4	QB 选 cancel=5
另一表评同索引	QB(save)=1	QA(cancel)=−2
目标 / δ	−.1 / −1.1	−2.8 / −2.8
当前项 post	.45（旧 QA=1）	−1.4（旧 QB=0）
另一表当前项	QB 仍为 0	QA 仍为 1

一次转移只更新一表；这两列不能顺序合并

控制流与成本：先核有效条件

条件	更新规则与界限
真终止	y=r；不求和、不 argmax、不读空后继表
非终止资料缺失	保存日志并立即返回；不写 Q / 更新计数
外部截断，原任务继续	有效旧 x′ / mask；ES 还需目标 π 可构一步目标，不需实际下一动作或续接
实现成本	ES 汇总合法动作；Double 两表存储、只写一项

reset 新图不能补旧后继；δ 小也不证明估计准确

主要应用：多步 GUI 的真实合同

合同层面	真实研究前必须补齐；全部【待确认】
状态、动作与策略	完整状态 / 合法 mask / 行为与目标 π Double 分支、估计快照与日志
奖励、反馈与边界	奖励折扣 / 独立结果反馈 / 真终止与截断 初态、reset、可达性及采集范围
评价、覆盖与成本	数据相关性 / 指标与评价策略 采集训练成本 / 推理执行成本
方法与非 RL 对照	SARSA / QL / ES / Double 是方法比较 固定流程、监督定位加流程是行为对照

真实十二合同未知；单次定位先判断是否需要 RL

三道理解题

1 复算 ES：3.4 → y / δ / post
SARSA 条件方差与 ES 的 0 能说明什么?

2 从原始两表分别核 A、B：选、评、写
真终止与非终止缺 mask 怎样处理?

3 E[max] 为什么 .5？独立 / 复制评价各多少?
列四项真实合同及一个非 RL 行为对照

独立作答后核对讲义文末答案；详细答案在备注

下一单元与原始参考来源

RL-019 表格控制的边界：收敛条件与数据覆盖

Sutton & Barto 第二版
§6.6 Expected SARSA；§6.7 Double Learning

Hado van Hasselt，2010，Double Q-learning
§2～3、Algorithm 1 与条件边界

人工快照与理论枚举；真实研究 NOT_RUN