RL-019

表格控制的边界：收敛条件与数据覆盖

2026-11-04 · 讲解约 13 分钟
学习 30～45 分钟

Q*、单次更新与长期收敛

$Q_{post}(s,a) = Q_{pre}(s,a) + \alpha_n(s,a)\,[Y_n - Q_{pre}(s,a)]$

真终止 $Y_n = r$
非终止 $Y_n = r + \gamma \max_{[合法u]} Q_{pre}(s',u)$

a.s.：在给定前提下，Q 值以概率 1 趋于 Q*

n 是当前状态动作对的有效更新编号；有限曲线无法证明无穷命题

单表 Q-learning 的充分条件

条件	准确范围
有限表格、完整状态	每个合法对独立存值，状态含义固定
平稳与正确反馈	同一 MDP 的奖励、转移与真实后继
有界奖励与折扣	初值有限，$0<\gamma<1$
无限有效覆盖	每个合法状态动作对均无限访问、更新
按对的步长	因果使用过去信息，逐对检查两和

充分条件不等于所有 RL 的必要且充分条件；Expected / Double 另核对应分析

按对步长与全局计时

每个合法 (s,a)：
$\Sigma_n \alpha_n(s,a)=\infty$，$\Sigma_n [\alpha_n(s,a)]^2<\infty$

稀有对：第 n 次更新发生于全局 $t_n=2^n$
用 $\alpha_t=1/t$，实际得到 $2^{(-n)}$

该对总步长 $\Sigma_n 2^{(-n)}=1$，第一和不满足

这是计数教学构造；没有运行训练或估计失败率

终止奖励：三次独立更新

新单步终止任务，两份 q0=0；奖励人为给定 +1、+1、−1

局部 n	奖励	常数 α=.5	按对 α_n=1/n
初始	—	0	0
1	+1	.5	1
2	+1	.75	1
3	−1	−.125	1/3

两副本各消费同三条记录；有限结果不能给出算法总排名

两和与原文严格步长上界

无限继续的序列	$\Sigma\alpha$	$\Sigma\alpha^2$	能调用哪部分条件
每次 .5	发散	发散	平方和条件不满足
按对 1/n	发散	收敛	两和成立，其他前提另核

原文 $0\le\alpha<1$；1/n 的首项 1 需单独解释

首步后以有限 q1 重起，尾步长 $1/(m+1)<1$

常数步长的持续噪声边界

独立教学假设：每次奖励公平独立 ±1，α=.5

$q_n=.5\,q_{(n-1)}+.5\,r_n$，始终在 $[-1,1]$

$r_n=2q_n-q_{(n-1)}$
若 q_n 收敛，r_n 也须收敛；持续两种符号排除此结论

只在该噪声设定下排除 a.s. 点收敛；不能概括为常数步长必无界发散

SARSA 的 GLIE 与 Q-learning 覆盖

控制方法	行为与目标关系	长期条件的区别
SARSA	下一实际行为动作	GLIE：每对无限探索 且行为极限贪心
Q-learning	合法后继估计最大值	行为可持续探索 仍须每对无限有效覆盖

ε→0 只约束非贪心分量，状态路径仍须论证

两者还需模型、反馈和按对步长条件；算法名字不提供自动保证

冻结 X/Y 反例：退火与路径覆盖

两次非贪心选择；同任务 $\varepsilon_m = 1/m$；排序冻结

$$p_m = [1/(2m)] \times [1/(2m)] = 1/(4m^2)$$

$$P(\text{曾访问}) \le \Sigma_m\, p_m \le .5$$
$$P(\text{从未访问}) \ge .5$$

并集界不需任务间独立；这是采集反例，不是训练或真实性能结果

有限日志与函数近似的证据边界

现象或安排	有限证据应怎样解释
曲线平、TD 差小	另核反馈、有效更新与独立评价
版本或状态含义改变	先判断是否仍为同一个 MDP
重复固定有限回放	不能补出未观测后果与原任务覆盖
DQN / 参数共享	须另查函数近似的分析与实验

有限计数、实际成本与未知区域可以报告；a.s. 命题没有有限训练时间表

四种目标机制与各自边界

方法	目标机制	本课保留的条件
SARSA	实际下一行为动作	最优控制另核 GLIE
Q-learning	合法后继估计 max	单表模型、覆盖、按对步长
Expected SARSA	按目标 π 求和	条件方差与长期收敛分开
Double Q	分表选择、评价	自身更新支、覆盖与步长

目标估计机制不会自动产生缺失反馈或修复覆盖

GUI 的覆盖、计数与受限任务

合同分组	全部真实字段【待确认】
状态与机会	完整状态 / 合法 mask / 初态与 reset 行为、目标、ε计时与版本
反馈与有效写入	奖励折扣 / 持久结果核验 / 终止截断 按对访问、目标与写入数 / 步长
评价、成本与对照	冻结评价与未知区域 / 采集训练成本 推理执行成本 / 非 RL 行为基线
任务范围	预先闭合定义受限 MDP 其 Q* 只属于明确的受限任务

不能事后删除未访对，声称原任务的全局最优

三道理解题

1 一万步、α=.5、ε→0、每页面见过一次
能否证明 SARSA、QL、DQN 都已到 Q*?

2 复算三奖励的两个副本与按对两和
首项 1、稀有全局时刻分别怎样解释?

3 冻结 X/Y 的覆盖界是什么?
列 GUI 四项合同与一个非 RL 对照

答案与必要前提在讲义文末及本页备注

下一单元与原始参考来源

RL-020 应用：
小型GUI导航中的安全探索与控制

Sutton & Barto 第二版原稿
§2.5，§6.4～6.5：步长、SARSA 与 Q-learning

Watkins & Dayan, 1992, Technical Note: Q-Learning
印刷 280～282；286 页有限经验讨论

教材与原始论文选读；教学推导非经验结果，真实研究 NOT_RUN