RL-020

应用：小型GUI导航中的安全探索与控制

2026-11-05 · 讲解约 13 分钟
学习 30～45 分钟

任务范围与学习目标

先定许可，再选行为与记录后果，最后独立评价

1 完整定义 N2 / C1 / z 与任务内预算
2 复算 SARSA、QL 的同 pre 独立写入
3 区分手算、模型参照与真实 GUI 证据

安全范围来自先验；confirm 仍有 .1 失败风险

N2 初态，C1 余一步；本课不包含 N1、C2，也不产生真实安全保证

两步导航 MDP 的完整转移

状态	动作	后继 / r	概率	结果
N2	review	C1 / −1	1	导航，未结束
N2	exit	z / 0	1	退出，非成功
C1	confirm	z / 8	.9	持久核验成功
C1	confirm	z / −4	.1	持久核验失败
C1	cancel	z / 0	1	取消，非成功

每动作消耗一预算；进入 z 的奖励保留，后续价值为 0

许可 mask 与 ε-greedy

$$b(a|x)=\varepsilon/k+(1-\varepsilon)/m \times 1\{\text{合法最大}\}$$

C1 候选	许可后的概率	候选与 Q 的身份
confirm，合法 Q=4	.9	合法，唯一最大
cancel，合法 Q=−2	.1	合法，探索可选
delete，外部评分=99	0	不属于本 MDP 的 Q 项

许可先验限制探索范围；合法不等于没有失败风险

两份 fresh pre 与独立规则流程

γ=.9，α=.5，ε=.2；初始化只在独立对照开始一次

合法状态动作	两学习副本的 Q_pre	有效写入 N
N2,review	1	0
N2,exit	0	0
C1,confirm	4	0
C1,cancel	−2	0

人为学习轨迹 review、cancel；非 RL 规则另行 review、confirm

行为动作与一步目标

非终止 SARSA：$y=r+\gamma\, Q_{pre}(x',a')$
非终止 QL：$y=r+\gamma \max_{[合法u]} Q_{pre}(x',u)$

真终止：两者 $y=r$，无下一动作

$\delta=y-Q_{pre}(x,a)$
$Q_{post}(x,a)=Q_{pre}(x,a)+\alpha\delta$

QL 的 max 读取估计；它不改变本次真实执行的动作或奖励

第一步 review：同 pre 的独立更新

量	SARSA 副本	Q-learning 副本
当前 pre	1	1
后继读取	已选 cancel 的 −2	合法 max(4,−2)=4
目标 y	−2.8	2.6
δ	−3.8	1.6
N2,review 的 post	−.9	1.8

两副本不串写；估计 4 不替换为模型均值 6.8 或奖励 8

沿用 cancel：终止写入与实际回报

cancel：r=0，d=1；y=0，δ=2，C1,cancel 的 post=−1

完成后合法项	SARSA Q	QL Q	各自 N
N2,review	−.9	1.8	1
N2,exit	0	0	0
C1,confirm	4	4	0
C1,cancel	−1	−1	1

两条实际 G 都是 −1；未访项只有初值，第一步不自动回写

规则流程的已知模型参照

C1：E[r|confirm]=.9×8+.1×(−4)=6.8

规则 review、confirm	概率	完整 G
持久核验成功	.9	−1+.9×8=6.2
持久核验失败	.1	−1+.9×(−4)=−4.6

模型内 V*(N2)=.9×6.2+.1×(−4.6)=5.12

真终止、截断与动作链

边界	当前目标与记录
真终止 / 任务内 h=0	y=r；保留结果标志，无下一动作
旧 C1、mask 有效，无 a′	QL 可一步目标；SARSA 留待核
有效 carry cancel，可续接	核任务、状态、许可后沿用同一动作
reset / 缺旧资料 / 待核反馈	新 N2 不补旧后继；不补写、不加有效计数

外部采集停止不自动变真终止；未知资料要保留原因

采集、更新与评价的最小顺序

步骤	必须保留的对象
1 定义与许可	任务、状态 / mask 与版本 / 方法先验
2 行为与真实反馈	x,a,r,x′ / 结束标志 / 独立结果
3 有效目标	SARSA a′ / carry；QL 合法 max
4 当前项写入	Q_pre、y、δ、Q_post / 按对有效 N
5 独立评价	冻结策略 / 持久成功 / 完整成本与空缺

这是待实现的工程顺序；没有执行采集、训练或真实性能试验

真实 GUI 合同与非 RL 对照

合同分组	真实字段全部【待确认】
任务与信息	状态 / 权限 mask / 规则与模型先验 行为、目标、快照、计数与版本
反馈、边界与数据	奖励单位 / 持久核验 / 终止截断 初态 reset / 真实日志、失败与空缺
评价与完整成本	冻结评价 / 违规、失败及不确定性 采集训练 / 推理执行、重置与核验
匹配的非 RL 基线	固定流程、监督定位加流程、示范 同任务、输入、许可、预算与成功判据

先核状态、许可与反馈，再决定是否需要学习控制

三道理解题

1 写出有限任务与许可
confirm / cancel / 外部 delete 的概率?

2 复算两份同 pre 的两次写入与 G
为什么不能用 5.12、−.9、1.8 排名?

3 旧 C1 有效但无 a′，随后 reset
两算法怎样处理？真实合同还缺什么?

参考答案在讲义文末及本页备注；先独立复算

下一单元与可核查来源

RL-021 复习：SARSA与Q-learning到底差在哪?

Sutton & Barto 第二版原稿
§2.2，§6.4 ~ 6.5：ε-greedy、SARSA 与 QL

Gymnasium 官方说明
Handling Time Limits；Action Masking

机制、教学手算与真实实验分开；研究、训练和 GUI 操作 NOT_RUN