RL-021

复习：SARSA与Q-learning到底差在哪?

2026-11-06 · 第 3 周总结 · 约 13 分钟
学习 30～45 分钟

第三周知识地图：数据、目标与结论

回链	本周核心对象	关键核查
RL-015	SARSA 与动作链	选 a′、读 pre、carry 同动作
RL-016	Q-learning 目标	合法 max 与实际行为分开
RL-017	探索与覆盖	合法分母、状态路径、计数
RL-018	目标估计	动作平均；分表选择与评价
RL-019	收敛边界	命题、长期前提与有限证据
RL-020	GUI 应用合同	许可、结束、持久结果与成本

本课同时承担周总结；每个回链仍指向原单元

四个对象：行为、目标、估计、回报

对象	回答的问题	本课例子
行为 b	实际执行什么?	人工 review、cancel
目标 y	这次朝哪个值推?	−2.8 或 2.6
估计 Q	当前表存什么?	1 写成 −.9 或 1.8
完整回报 G	完整轨迹收到什么?	−1+.9×0=−1

post、一步目标、单条 G 与真实价值属于不同对象

共享写入骨架，不同后继项

真终止 $y_M=r$；非终止 $y_M=r+\gamma Z_M(x')$

$Z_{SARSA}=Q_{pre}(x',a')$
$Z_{QL}=\max_{\text{合法}u} Q_{pre}(x',u)$

$\delta_M=y_M-Q_{pre_M}(x,a)$
$Q_{post_M}(x,a)=Q_{pre_M}(x,a)+\alpha\delta_M$

一次选到最大动作可使目标相同；不能推断整个训练等价

同一任务，重新开始的独立 pre

γ=.9，α=.5，ε=.2；N2、C1、z 完全沿用 RL-020

合法状态动作	每份 fresh Q_pre	有效写入 N
N2,review	1	0
N2,exit	0	0
C1,confirm	4	0
C1,cancel	−2	0

初始行为两合法动作 .9/.1；许可外 delete=99 不属于 Q

同一 review 转移：两种主目标

第一步量	SARSA 独立副本	QL 独立副本
当前 pre	1	1
后继项	已选 cancel 的 −2	合法 max(4,−2)=4
目标 y	−2.8	2.6
δ	−3.8	1.6
Nreview 的 post	−.9	1.8

两列同一原始 pre；目标读到 confirm，不等于执行或观察了它

第三份独立 ES：对动作求平均

ES 量	同一原始 pre 的独立计算
后继动作均值 Z_ES	$.9\times4+.1\times(-2)=3.4$
目标 y	$-1+.9\times3.4=2.06$
δ	$2.06-1=1.06$
Nreview 的 post	$1+.5\times1.06=1.53$

π=b；只平均给定条件下的下一动作，1.53 不接在两主表后写入

实际 cancel：终止写入与 G

两条主轨迹 r=(−1,0)，完整 G=−1，均非成功

完成后合法项	SARSA	QL	每份有效 N
N2,review	−.9	1.8	1
N2,exit	0	0	0
C1,confirm	4	4	0
C1,cancel	−1	−1	1

真终止 y=0，Ccancel 从 −2 到 −1；未访项不是已经学准

模型期望、路径回报与估计

数字对象	数值	准确含义
confirm 初始估计	4	表中初值，未执行的反馈未知
confirm 模型期望奖励	6.8	.9×8+.1×(−4)
规则两条路径 G	6.2 / −4.6	成功 / 失败的完整回报
规则模型期望	5.12	.9×6.2+.1×(−4.6)

规则有先验；模型期望、目标、post 与实际 G 不能直接排名效果

截断后，当前目标还是否有效

记录条件	QL	SARSA	ES
真终止	y=r	y=r	y=r
外停：旧 C1、mask 有效 无已选 a′	合法 max 可构目标	待核 不补 a′	有效 π 可求均值
旧后继或 mask 缺失	留原因 跳过写入	留原因 跳过写入	留原因 跳过写入
随后 reset 到新 N2	新图不补旧后继	新动作不补旧链	新图不补旧后继

合法资料与原任务边界分别核对；跳过写入不增加有效更新计数

按错因复习：六个最短回查入口

错因	回查	最短检查
a′ 与下一执行不一致	015	读 pre，carry 同一动作
max 被当成已执行	016	分开估计、动作与反馈
ε 被当成覆盖证书	017	合法分母、路径、实际计数
平均 / 双表被当万能	018	条件、选评索引、唯一写入支
有限稳定被当长期保证	019	逐项核问题、步长与访问
许可或提示被当成功	020	核许可先验与持久结果

回原单元查错因，再回本课复算；不据无反馈判断个人掌握

GUI 比较：反馈、合同与完整成本

合同分组	真实定义全部【待确认】
状态、许可与信息	完整状态 / 合法 mask 与版本 / 方法先验 行为与目标 / 快照、计数和动作链
反馈、结束与数据	奖励单位 / 独立持久核验 / 终止截断 初态 reset / 失败、缺失和覆盖分母
评价与完整成本	冻结评价 / 错误后果与不确定性 采集训练 / 推理、执行、重置与核验
匹配非 RL 基线	固定流程、监督定位加流程、示范 同任务、输入、权限、预算与成功判据

数值目标、点击命中与业务持久完成分别核验

三道理解题

1 同一 pre：算 SARSA、QL、独立 ES
再给两张主表、有效计数与完整 G

2 一次目标相同，是否整个训练等价?
覆盖、双表独立、5.12 各易错在哪里?

3 外停无 a′：QL / SARSA / ES 能算什么?
列真实反馈、基线及训练 / 推理成本

先独立复算，再核文末答案；按错因回到原单元

下一阶段与可核查来源

RL-022 DQN：用神经网络近似动作价值

Sutton & Barto 第二版原稿
§6.4 ~ 6.7：动作目标、动作平均与双估计

Gymnasium 官方概念说明
时间限制；动作 mask；本周六课稳定回链

DQN 本课只预告；没有随机采样、训练、真实 GUI 或性能提升结果