RL-022

DQN：用神经网络近似动作价值

2026-11-07 · 讲解约 13 分钟
学习 30～45 分钟

表格值与共享参数预测

独立 Q 表项，改为共享函数 Q(s,a;θ)

1 读懂动作向量、稳定编号与合法 mask
2 固定目标，计算一次半梯度写入
3 重算其他输出，检查证据边界

一次记录改变参数，未访问预测也可能变化

当前课只解释近似与一次回归接口；完整 DQN 还有回放与目标网络

四个固定输出与合法 mask

接口	ID 0	ID 1	ID 2	ID 3
固定动作	review	exit	confirm	cancel
N2 mask	1	1	0	0
C1 mask	0	0	1	1

Q 是长期价值估计，可负、无需归一化

动作概率另由行为规则定义；状态编码不自动证明输入是完整状态

固定快照构造一步目标

真终止：y=r

非终止：
y=r+γ max[合法u] Q(s′,u;θ_bar)

本步 θ_bar 固定；当前预测使用 θ
max 读取估计，不等于执行该动作

进入终态的奖励保留；reset 新图不能补原任务后继

半平方损失与停止梯度

$$\ell(\theta)=\tfrac{1}{2}\,[Q(s,a;\theta)-\mathrm{SG}(y)]^2$$

$$\delta=y-Q(s,a;\theta)$$
$$\nabla_\theta \ell=(Q-y)\nabla_\theta Q=-\delta\nabla_\theta Q$$

$$\theta_{new}=\theta-\eta\nabla_\theta\ell=\theta+\eta\delta\nabla_\theta Q$$

SG 前向保留 y，反向对当前 θ 的梯度为 0；只读当前已执行动作预测

线性共享模型：可手算的替身

$$Q(s,a;\theta)=k(s,a)w+b,\ \theta_0=(w,b)=(1,0)$$

固定 k(s,a)	review	exit	confirm	cancel
N2	1	0	0	0
C1	0	0	4	−2

线性两参数仅为教学；合法初始预测为 (1,0,4,−2)，不继承前课终表

同一记录：目标、预测与初始损失

本次固定接口	数值
目标 y	$-1+.9\times\max(4,-2)=2.6$
当前预测 q0	1
δ0	$2.6-1=1.6$
半平方损失 ℓ0	$\frac{1}{2}\times(1-2.6)^2=1.28$
当前预测梯度 ∇Q	(1,1)

θ_bar=θ0 在本步固定；η=.1 重新指定，不是前课 α=.5

一次参数梯度下降

$$\nabla\theta\ell=(1-2.6)\times(1,1)=(-1.6,-1.6)$$

$\eta=.1$
$\theta 1=(1,0)-.1\times(-1.6,-1.6)$

$\theta 1=(1.16,.16)$；θ_bar 仍是 (1,0)

一次样本的梯度算术；参数写入不是新增环境反馈

共享参数：未访问预测也会变化

合法项	Q(θ0)	Q(θ1)	本次新记录
N2,review	1	1.32	仅这一对有一条
N2,exit	0	.16	无
C1,confirm	4	4.8	无
C1,cancel	−2	−2.16	无

参数共享会传播变化；预测变化不等于覆盖、监督或正确价值

固定目标下的损失与合同

固定 y=2.6：
$\ell 1 = \frac{1}{2} \times (1.32 - 2.6)^2 = .8192 < 1.28$

若本步改用 θ1：−1+.9×4.8=3.32
这替换了声明冻结的 θ_bar

未来按明确协议重构目标，属于另一轮计算

本次 loss 下降不是性能证据；目标长期维护留到 RL-024

有效目标、任务边界与完整方法

范围或记录	准确处理
独立真终止记录：r=8	y=8；不再执行第二次梯度
外停：旧 C1 / mask 有效	原任务继续，固定快照 y=2.6
旧资料缺失 / 只剩 reset 图	留原因，跳过无法核实的更新
完整 2015 DQN	回放与目标网络等组成后续细讲

表格保证、泛化、训练稳定与业务完成是不同命题

有限候选下的多步 GUI 合同

合同分组	真实定义全部【待确认】
状态、输出与许可	观测与历史 / 稳定动作 ID / 合法 mask 初态、reset、期限与真实后继
反馈、数据与优化	奖励与持久核验 / 覆盖、版本与缺失 目标快照、SG、损失系数与学习率
评价与完整成本	冻结评价 / 错误后果与不确定性 采集训练、显存 / 推理执行与核验
匹配非 RL 基线	固定流程、监督定位加流程、示范 同输入、先验、权限、预算与成功判据

共享表示的收益与干扰，需要真实数据和独立评价

三道理解题

1 输出 ID、mask 与动作概率是什么关系？
截图编码为何不自动得到完整状态？

2 复算 y、梯度、θ1、四个输出与固定 loss
哪些未访问项变化？能证明什么？

3 真终止 / 外停 / reset 怎样处理？
3.32 违反哪一轮合同？真实研究还缺什么？

先复算再核文末答案；两参数例不能称为深度 DQN 训练

下一单元与原始论文

RL-023 经验回放：旧数据如何帮助训练

Mnih et al., 2013
Playing Atari with Deep Reinforcement Learning

Mnih et al., 2015, Nature
Human-level control through deep reinforcement learning

固定快照只是本次接口；未复现原论文优化、实验或 Atari 性能