RL-023

经验回放：旧数据如何帮助训练

2026-11-08 · 讲解约 13 分钟
学习 30～45 分钟

环境经验与优化使用分开计数

真实事件产生记录；回放复用记录做优化

1 声明容量、有效 N、抽样单位与批大小
2 同一 pre 求两条梯度均值，再写一次
3 核覆盖、版本、反馈与完整成本

再次使用 ≠ 新交互、独立奖励或新动作反馈

今天只给本步固定目标快照；长期目标维护留到 RL-024

三条转移，来自两个任务

容量 C=3，当前有效 N=3；人工给定，不运行采集或抽样器

事件 / 任务步	s	已执行 a	r	原 s′	d
e1 / A1	N2	review	−1	C1	0
e2 / A2	C1	cancel	0	z	1
e3 / B1	N2	exit	0	z	1

三个唯一事件，两个完整任务；confirm 的实际反馈仍为 0 条

均匀抽样：分母与放回方式

概率对象 / 协议	本课数值或选择
单条 ID 概率	1/3
任务 A / B 的概率质量	2/3 / 1/3
三种无序二元子集	各 1/3
每条整批纳入概率	B/N=2/3
本次人工指定批	{e1,e2}，仍是相邻转移

B=2 无放回是教学协议；本课未运行随机采样

同一 pre 下的批均值目标

$$\ell_i = \tfrac{1}{2}\,[Q(s_i,a_i;\theta) - SG(y_i)]^2$$

$$L_B = (1/B)\,\Sigma_i\,\ell_i$$
$$\nabla\theta L_B = (1/B)\,\Sigma_i\,(q_i - y_i)\nabla\theta Q_i$$

$\theta_{new} = \theta - \eta\nabla\theta L_B$；先全批读取，再写一次

全批使用同一 pre 参数及固定目标快照；不是两次顺序 SGD

同一任务、特征与重新初始化

Q=k(s,a)w+b；重新 θ0=(1,0)，η=.1

固定 k(s,a)	review	exit	confirm	cancel
N2	1	0	0	0
C1	0	0	4	−2

线性教学替身，θ_bar=θ0 仅本步固定；不承接 RL-022 参数终值

两条损失梯度：先读同一 θ0

同 pre 的量	e1：Nreview	e2：Ccancel
k / 当前预测 q	1 / 1	−2 / −2
目标 y	2.6	0，真终止
δ=y−q	1.6	2
半平方损失	1.28	2
∇Q	(1,1)	(−2,1)
损失梯度	(−1.6,−1.6)	(4,−2)

不同特征先各自乘梯度，再求均值；不把第一行 post 带入第二行

一次批平均写入

$$L_B(\theta 0) = (1.28 + 2)/2 = 1.64$$

$$\nabla L_B = [(-1.6, -1.6) + (4, -2)]/2$$
$$= (1.2, -1.8)$$

$$\theta 1 = (1,0) - .1 \times (1.2, -1.8) = (.88, .18)$$

批梯度方向可部分抵消；不是平均 δ 后随意乘一个共同特征

共享预测与本批固定目标损失

合法项	Q(θ0)	Q(θ1)	buffer 事件数
N2,review	1	1.06	1
N2,exit	0	.18	1，本批未选
C1,confirm	4	3.7	0
C1,cancel	−2	−1.58	1

固定 y=(2.6,0)：新批均值 loss=1.217

单批梯度与全 buffer 条件期望

可能批次	子集概率	同 pre 梯度
{e1,e2}	1/3	(1.2,−1.8)
{e1,e3}	1/3	(−.8,−.8)
{e2,e3}	1/3	(2,−1)
条件平均 / 全 D	—	(.8,−1.2)

全 D 初 loss=82/75；条件采样性质不保证原环境或 Q* 无偏

复用、容量与历史数据边界

安排或风险	必须保留的区分
重复使用旧 ID	使用数 / 更新数增加，事件数不增
FIFO 容量 3，假设新增 e4	历史总数 4，当前仍 3
版本不兼容	核查、隔离或有依据重建，不悄改反馈
相邻 / 复制记录跨 train/test	先按独立任务与场景划分，防泄漏

回放不是环境模型，不生成未观察到的随机后果或保证全动作覆盖

GUI 旧日志：协议与完整成本

合同分组	真实定义全部【待确认】
状态、许可与反馈	完整输入 / 稳定 ID 与旧 mask / 持久核验 期限、reset、初态与真实原后继
事件、协议与优化	唯一事件、任务版本 / 容量、淘汰与采样 同 pre、SG、mean、使用数与更新数
评价与完整成本	当前 / 历史覆盖；独立评价与非 RL 对照 交互核验、图像存取、更新及推理执行
数据划分与公平性	按独立任务 / 场景划分 train、调参、test 匹配信息、权限、交互 / 计算预算和判据

旧日志能否减少交互需求，需要真实数据与独立测试

三道理解题

1 单条、子集、整批纳入各用什么分母？
重放旧 ID 增加什么，不增加什么？

2 同 pre 算梯度、参数和固定目标新批 loss
本批梯度为何可与全 buffer 不同？

3 复制成功轨迹、混版本、拆转移做测试
哪里会错？真实 GUI 还缺哪些协议与成本？

先独立复算，再核文末答案；本课未运行采样、训练或 GUI

下一单元与原始论文

RL-024 目标网络：为什么不用自己追自己

Mnih et al., 2013
Playing Atari with Deep Reinforcement Learning

Mnih et al., 2015, Nature
Human-level control through deep reinforcement learning

选读原文回放与 minibatch；本课不实现目标维护或复现 Atari 实验