RL-024

目标网络：为什么不用自己追自己

2026-11-09 · 讲解约 13 分钟
学习 30～45 分钟

移动目标与两组参数

在线网络更新预测；目标网络提供后继估计

1 区分本次停止梯度与跨优化步的参数维护
2 按时钟复算硬复制和独立软分支
3 核对目标版本、结束事实和完整成本

目标值仍是估计；滞后并不产生真实答案

两份参数可从同一初值复制，但需要分别保存和维护

回放、停止梯度与目标维护

机制	控制的部分	仍需检查
回放	记录的使用顺序与频率	历史版本、偏向与未覆盖动作
stop-gradient	当前 loss 的反向路径	下一次使用哪组目标参数
硬复制	间隔后复制整组 post 参数	优化时钟、滞后与边界跳变
软维护	逐次混合旧目标与 post 在线参数	τ 的权重约定及维护频率

一次优化内的固定目标，与优化之间的维护，分别记录

本次目标、损失与反向范围

真终止：y_i = r_i
非终止：y_i = r_i + γ max合法u Q(s′_i,u;barθ_j)

$$L_j(\theta) = (1/B)\ \Sigma_i\ ½\ [Q(s_i,a_i;\theta) - SG(y_i)]^2$$

θ_j → θ_(j+1)；本次损失只更新在线 θ

j 为已完成的优化次数；本次读取 pre θ_j 与 pre barθ_j

硬复制的顺序与优化时钟

pre 目标 → online step → c 加 1
达到 H 的倍数 → 复制 post θ → 下一目标

本课 H=2，c 从 0 开始并保留
c=1 保持 barθ；c=2 复制；下次在 c=4

B=2 的一批只算一次成功 optimizer step

H 为正整数；采集环境、重复读记录、跳过无效更新均不另加 c

同一教学任务，独立初始化

Q=k(s,a)w+b；θ0=barθ0=(1,0)
η=.1，γ=.9；固定批 {Nreview, Ccancel}

固定 k(s,a)	review	exit	confirm	cancel
N2	1	0	0	0
C1	0	0	4	−2

线性替身；不承接 RL-023 终值，不运行采样器或深度训练

共同第 1 次优化

同 pre 的量	e1：Nreview	e2：Ccancel
当前预测 q	1	−2
固定目标 y	2.6	0，真终止
损失梯度	(−1.6,−1.6)	(4,−2)
批均值梯度	(1.2,−1.8)	一次 online 写入

θ1=(.88,.18)；c=1

共同 θ1 边界的三种维护

维护选择	维护后的 barθ	下次 Nreview 目标
硬 H=2，c=1	(1,0)，不复制	2.6
每步复制 H=1	(.88,.18)	2.33
独立软 τ=.1	(.988,.018)	2.573

只比较共同首步后的目标；H=1 与软分支到此停止

硬 H=2：第 2 次仍用旧目标

本次的量	e1：Nreview	e2：Ccancel
pre 在线预测	1.06	−1.58
固定目标 y	2.6	0
q−y	−1.54	−1.58
损失梯度	(−1.54,−1.54)	(3.16,−1.58)

均值 (.81,−1.56) → θ2=(.799,.336)

c=2 之后复制，只影响下一目标

完成 θ2 写入 → c=2 → barθ2 ← θ2

Q(C1,confirm;barθ2)=3.532
Q(C1,cancel;barθ2)=−1.262

下一次：y = −1 + .9×3.532 = 2.1788

第 2 次用的是 2.6；c 保留为 2，下次复制在成功 step 4 之后

软参数维护的权重与滞后

$$\text{bar}\theta_{new} = (1-\tau)\,\text{bar}\theta_{old} + \tau\,\theta_{post}$$

τ 乘新在线参数；0≤τ≤1
τ=0 保持目标；τ=1 每步后直接复制

参数插值；非线性 Q 输出通常不能直接平均

本课 soft 只演示首步后一次维护，不与硬分支串写

GUI：目标版本、结束事实与成本

真实合同分组	定义与接口全部【待确认】
任务与反馈	完整输入、ID/mask、独立持久核验 多步预算、真终止/外截断/reset、旧后继
数据与参数版本	事件/回放版本、两网络分别保存 pre/post、H/τ 时钟、成功 step 与维护事件
评价与完整成本	独立持久成功、回报/违规/覆盖与非 RL 对照 采集核验、两网络前向/存储/维护及部署
公平比较与边界	同任务、权限、输入、预算和成功判据 目标缓变只是诊断，研究尚未运行

真终止保留 r；外部停止要核对原后继与目标版本

三道理解题

1 stop-gradient 与维护各约束什么？
H=2、B=2：c 何时增加、复制影响哪一步？

2 复算共同首步、硬两步与独立软维护
2.1788 能否回改第 2 次目标？分支能否拼接？

3 真终止 r=8、有效外截断、仅 reset 新图各怎样？
补真实 GUI 判据、非 RL 基线与训练/推理成本

先自行作答，再核讲义文末答案；本课无训练或真实 GUI 实验

下一单元与原始来源

RL-025 Double DQN：选择动作与评估动作分开

Mnih et al., Nature 2015
Human-level control through deep reinforcement learning

Lillicrap et al., ICLR 2016
Continuous control with deep reinforcement learning

硬复制：DQN；软维护式：DDPG v6（2019 修订）的限定选页